

# Modelagem Estocástica de Redes Neurais

**Aline Duarte**


Universidade de São Paulo/ CEPID NeuroMat



Universidade Federal Fluminense



25 de outubro de 2017

## NeuroMat

Research, Innovation and  
Dissemination Center for  
Neuromathematics

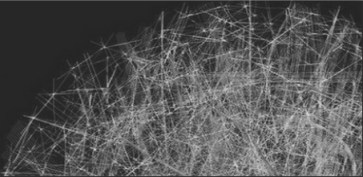
Search... 

 Português  English

[About NeuroMat](#) [Research](#) [Tools](#) [In the media](#) [Events](#) [Opportunities](#)  

Planta by Leon Ferrari

# NeuroMat





NeuroMat -  
Research Center  
for  
Neuromathematics  
@neuromathematics

Página inicial

# NeuroMat



 Curtiu ▾

 Seguindo ▾

 Compartilhar

 ...

 Enviar mensagem



# Potencial de membrana e disparos

Potencial de Membrana = **Diferença** em voltagem entre o interior e exterior da membrana celular.

# Potencial de membrana e disparos

$$\begin{array}{l} \text{Potencial de} \\ \text{Membrana} \end{array} = U_t \in [0, \infty)$$

# Potencial de membrana e disparos

$$\begin{array}{l} \text{Potencial de} \\ \text{Membrana} \end{array} = U_t \in [0, \infty)$$

## Evolução temporal

1. O neurônio acumula potencial devido a uma corrente  $C_t$  estímulo (em razão de outros neurônios ou de um estímulo externo)
2. A ocorrência de um disparo depende do potencial de membrana (quanto maior o potencial, maior a probabilidade de disparar)
3. Quando um neurônio dispara, perde todo potencial acumulado

# Modelo para disparos de um único neurônio



# Modelo Integra-e-dispara **determinístico** (Lapicque 1907)

Fixe um tempo  $t \geq 0$

- ▶  $C_t \in (0, \infty)$ : corrente estímulo
- ▶  $L_t \in (-\infty, t]$ : o tempo de último disparo do neurônio

$$\text{▶ } U_t = \sum_{s=L_t+1}^t C_s$$

# Modelo Integra-e-dispara **determinístico** (Lapicque 1907)

Fixe um tempo  $t \geq 0$

- ▶  $C_t \in (0, \infty)$ : corrente estímulo
- ▶  $L_t \in (-\infty, t]$ : o tempo de último disparo do neurônio

$$\text{▶ } U_t = \sum_{s=L_t+1}^t C_s$$

- ▶ Continuo somando até que  $U_t = \sum_{s=L_t+1}^t C_s \geq \vartheta$ , então  $U_{t+1} = 0$

# Simulação **determinística** de um único neurônio

$$U_t = \sum_{s=L_t+1}^t C_s$$

Suponha

- ▶  $C_t \equiv 1, t \in \mathbb{N}$
- ▶  $U(0) = 0$
- ▶  $\vartheta = 4$

# Simulação **determinística** de um único neurônio

$$U_t = \sum_{s=L_t+1}^t C_s$$

Suponha

- ▶  $C_t \equiv 1, t \in \mathbb{N}$
- ▶  $U(0) = 0$
- ▶  $\vartheta = 4$

Nesse caso

- ▶  $U_1 = 0 + 1 = 1$

# Simulação **determinística** de um único neurônio

$$U_t = \sum_{s=L_t+1}^t C_s$$

Suponha

- ▶  $C_t \equiv 1, t \in \mathbb{N}$
- ▶  $U(0) = 0$
- ▶  $\vartheta = 4$

Nesse caso

- ▶  $U_1 = 0 + 1 = 1$
- ▶  $U_2 = 1 + 1 = 2$

# Simulação **determinística** de um único neurônio

$$U_t = \sum_{s=L_t+1}^t C_s$$

Suponha

- ▶  $C_t \equiv 1, t \in \mathbb{N}$
- ▶  $U(0) = 0$
- ▶  $\vartheta = 4$

Nesse caso

- ▶  $U_1 = 0 + 1 = 1$
- ▶  $U_2 = 1 + 1 = 2$
- ▶  $U_3 = 3, U_4 = 4$

# Simulação **determinística** de um único neurônio

$$U_t = \sum_{s=L_t+1}^t C_s$$

Suponha

- ▶  $C_t \equiv 1, t \in \mathbb{N}$
- ▶  $U(0) = 0$
- ▶  $\vartheta = 4$

Nesse caso

- ▶  $U_1 = 0 + 1 = 1$
- ▶  $U_2 = 1 + 1 = 2$
- ▶  $U_3 = 3, U_4 = 4$
- ▶  $U_5 = 0$

# Simulação **determinística** de um único neurônio

$$U_t = \sum_{s=L_t+1}^t C_s$$

Suponha

- ▶  $C_t \equiv 1, t \in \mathbb{N}$
- ▶  $U(0) = 0$
- ▶  $\vartheta = 4$

Nesse caso

- ▶  $U_1 = 0 + 1 = 1$
- ▶  $U_2 = 1 + 1 = 2$
- ▶  $U_3 = 3, U_4 = 4$
- ▶  $U_5 = 0$
- ▶  $U_6 = 1, U_7 = 2 \dots$



# Simulação **determinística** de um único neurônio

$$U_t = \sum_{s=L_t+1}^t C_s$$

Observe que

$$\blacktriangleright U_1 = 0 + 1 = U_0 + 1$$

Suponha

$$\blacktriangleright C_t \equiv 1, \quad t \in \mathbb{N}$$

$$\blacktriangleright U(0) = 0$$

$$\blacktriangleright \vartheta = 4$$

Nesse caso

$$\blacktriangleright U_1 = 0 + 1 = 1$$

$$\blacktriangleright U_2 = 1 + 1 = 2$$

$$\blacktriangleright U_3 = 3, \quad U_4 = 4$$

$$\blacktriangleright U_5 = 0$$

$$\blacktriangleright U_6 = 1, \quad U_7 = 2 \dots$$

# Simulação **determinística** de um único neurônio

$$U_t = \sum_{s=L_t+1}^t C_s$$

Observe que

$$\blacktriangleright U_1 = 0 + 1 = U_0 + 1$$

$$\blacktriangleright U_2 = U_1 + 1$$

Suponha

$$\blacktriangleright C_t \equiv 1, \quad t \in \mathbb{N}$$

$$\blacktriangleright U(0) = 0$$

$$\blacktriangleright \vartheta = 4$$

Nesse caso

$$\blacktriangleright U_1 = 0 + 1 = 1$$

$$\blacktriangleright U_2 = 1 + 1 = 2$$

$$\blacktriangleright U_3 = 3, \quad U_4 = 4$$

$$\blacktriangleright U_5 = 0$$

$$\blacktriangleright U_6 = 1, \quad U_7 = 2 \dots$$

# Simulação **determinística** de um único neurônio

$$U_t = \sum_{s=L_t+1}^t C_s$$

Observe que

- ▶  $U_1 = 0 + 1 = U_0 + 1$
- ▶  $U_2 = U_1 + 1$
- ▶  $U_3 = U_2 + 1, U_4 = U_3 + 1,$

Suponha

- ▶  $C_t \equiv 1, t \in \mathbb{N}$
- ▶  $U(0) = 0$
- ▶  $\vartheta = 4$

Nesse caso

- ▶  $U_1 = 0 + 1 = 1$
- ▶  $U_2 = 1 + 1 = 2$
- ▶  $U_3 = 3, U_4 = 4$
- ▶  $U_5 = 0$
- ▶  $U_6 = 1, U_7 = 2 \dots$

# Simulação **determinística** de um único neurônio

Observe que

$$U_t = \sum_{s=L_t+1}^t C_s$$

Suponha

- ▶  $C_t \equiv 1, t \in \mathbb{N}$
- ▶  $U(0) = 0$
- ▶  $\vartheta = 4$

Nesse caso

- ▶  $U_1 = 0 + 1 = 1$
- ▶  $U_2 = 1 + 1 = 2$
- ▶  $U_3 = 3, U_4 = 4$
- ▶  $U_5 = 0$
- ▶  $U_6 = 1, U_7 = 2 \dots$

- ▶  $U_1 = 0 + 1 = U_0 + 1$
- ▶  $U_2 = U_1 + 1$
- ▶  $U_3 = U_2 + 1, U_4 = U_3 + 1,$
- ▶  $U_5 = 0 \neq U_4 + 1$

# Simulação **determinística** de um único neurônio

Observe que

$$U_t = \sum_{s=L_t+1}^t C_s$$

Suponha

- ▶  $C_t \equiv 1, t \in \mathbb{N}$
- ▶  $U(0) = 0$
- ▶  $\vartheta = 4$

Nesse caso

- ▶  $U_1 = 0 + 1 = 1$
- ▶  $U_2 = 1 + 1 = 2$
- ▶  $U_3 = 3, U_4 = 4$
- ▶  $U_5 = 0$
- ▶  $U_6 = 1, U_7 = 2 \dots$

- ▶  $U_1 = 0 + 1 = U_0 + 1$
- ▶  $U_2 = U_1 + 1$
- ▶  $U_3 = U_2 + 1, U_4 = U_3 + 1,$
- ▶  $U_5 = (U_4 + 1)1_{\{U_4 \leq 4\}}$

# Simulação **determinística** de um único neurônio

$$U_t = \sum_{s=L_t+1}^t C_s$$

Suponha

- ▶  $C_t \equiv 1, t \in \mathbb{N}$
- ▶  $U(0) = 0$
- ▶  $\vartheta = 4$

Nesse caso

- ▶  $U_1 = 0 + 1 = 1$
- ▶  $U_2 = 1 + 1 = 2$
- ▶  $U_3 = 3, U_4 = 4$
- ▶  $U_5 = 0$
- ▶  $U_6 = 1, U_7 = 2 \dots$

Observe que

- ▶  $U_1 = (U_0 + 1)1_{\{U_0 \leq 4\}}$
- ▶  $U_2 = (U_1 + 1)1_{\{U_1 \leq 4\}}$
- ▶  $U_3 = (U_2 + 1)1_{\{U_2 \leq 4\}}$
- ▶  $U_4 = (U_3 + 1)1_{\{U_3 \leq 4\}}$
- ▶  $U_5 = (U_4 + 1)1_{\{U_4 \leq 4\}}$
- ▶  $U_6 = (U_5 + 1)1_{\{U_5 \leq 4\}}$
- ▶  $U_7 = (U_6 + 1)1_{\{U_6 \leq 4\}}$

$$U_k = f(U_{k-1})$$

# Modelo Integra-e-dispara **estocástico**

Fixe um tempo  $t > \mathbb{Z}$

- ▶  $C_t \equiv c$ : corrente estímulo **constante**
- ▶  $L_t \in (-\infty, t)$ : tempo de último disparo do neurônio

$$\text{▶ } U_t = \sum_{s=L_t+1}^t c \quad \text{▶ } U_t = \begin{cases} U_{t-1} + c, & \text{se não dispara no tempo } t \\ 0, & \text{se dispara no tempo } t \end{cases}$$

# Modelo Integra-e-dispara **estocástico**

Fixe um tempo  $t > \mathbb{Z}$

- ▶  $C_t \equiv c$ : corrente estímulo **constante**
- ▶  $L_t \in (-\infty, t)$ : tempo de último disparo do neurônio

$$\text{▶ } U_t = \sum_{s=L_t+1}^t c \quad \text{▶ } U_t = \begin{cases} U_{t-1} + c, & \text{se não dispara no tempo } t \\ 0, & \text{se dispara no tempo } t \end{cases}$$

- ▶  $\mathbb{P}(U_{t+1} = 0 \mid U_t) = \varphi(U_t)$ 
  - ▶  $\varphi : [0, \infty) \rightarrow [0, 1]$  **função probabilidade de disparo**



# Modelo Integra-e-dispara **estocástico**

Fixe um tempo  $t > \mathbb{Z}$

- ▶  $C_t \equiv c$ : corrente estímulo **constante**
- ▶  $L_t \in (-\infty, t)$ : tempo de último disparo do neurônio

$$\text{▶ } U_t = \sum_{s=L_t+1}^t c \quad \text{▶ } U_t = \begin{cases} U_{t-1} + c, & \text{se não dispara no tempo } t \\ 0, & \text{se dispara no tempo } t \end{cases}$$

- ▶  $\mathbb{P}(U_{t+1} = 0 \mid U_t) = \varphi(U_t)$ 
  - ▶  $\varphi : [0, \infty) \rightarrow [0, 1]$  **função probabilidade de disparo**

$\Rightarrow (U_t)_{t \geq 0}$  é uma **cadeia de Markov de ordem 1**

Sejam  $\xi_1, \xi_2, \dots$  v.a's iid com distribuição uniforme em  $[0, 1]$ .

### Definição: Cadeia de Markov

Um processo  $U_0, U_1, U_2, \dots$  tomando valores em um alfabeto  $A$  é uma *cadeia de Markov de ordem 1*, com estado inicial  $a \in A$ , se  $U_0 = a$  e existe uma função  $f : A \times [0, 1] \rightarrow A$  tal que para todo  $t \geq 0$

$$U_{t+1} = f(U_t, \xi_{t+1})$$

Sejam  $\xi_1, \xi_2, \dots$  v.a's iid com distribuição uniforme em  $[0, 1]$ .

### Definição: Cadeia de Markov

Um processo  $U_0, U_1, U_2, \dots$  tomando valores em um alfabeto  $A$  é uma *cadeia de Markov de ordem 1*, com estado inicial  $a \in A$ , se  $U_0 = a$  e existe uma função  $f : A \times [0, 1] \rightarrow A$  tal que para todo  $t \geq 0$

$$U_{t+1} = f(U_t, \xi_{t+1})$$

**No nosso modelo para neurônio:**

1.  $U_{t+1} = \begin{cases} U_t + c, & \text{se não dispara no tempo } t + 1 \\ 0, & \text{se dispara no tempo } t + 1 \end{cases}$
2.  $\mathbb{P}(U_{t+1} = 0 \mid U_t) = \varphi(U_t)$

Sejam  $\xi_1, \xi_2, \dots$  v.a's iid com distribuição uniforme em  $[0, 1]$ .

### Definição: Cadeia de Markov

Um processo  $U_0, U_1, U_2, \dots$  tomando valores em um alfabeto  $A$  é uma *cadeia de Markov de ordem 1*, com estado inicial  $a \in A$ , se  $U_0 = a$  e existe uma função  $f : A \times [0, 1] \rightarrow A$  tal que para todo  $t \geq 0$

$$U_{t+1} = f(U_t, \xi_{t+1})$$

**No nosso modelo para neurônio:**

$$1. \quad U_{t+1} = \begin{cases} U_t + c, & \text{com prob } 1 - \varphi(U_t) \\ 0, & \text{com prob } \varphi(U_t) \end{cases}$$

Sejam  $\xi_1, \xi_2, \dots$  v.a's iid com distribuição uniforme em  $[0, 1]$ .

### Definição: Cadeia de Markov

Um processo  $U_0, U_1, U_2, \dots$  tomando valores em um alfabeto  $A$  é uma *cadeia de Markov de ordem 1*, com estado inicial  $a \in A$ , se  $U_0 = a$  e existe uma função  $f : A \times [0, 1] \rightarrow A$  tal que para todo  $t \geq 0$

$$U_{t+1} = f(U_t, \xi_{t+1})$$

**No nosso modelo para neurônio:**

$$1. \quad U_{t+1} = \begin{cases} U_t + c, & \text{com prob } 1 - \varphi(U_t) \\ 0, & \text{com prob } \varphi(U_t) \end{cases}$$

$$U_{t+1} = f(U_t, \xi_{t+1}) = (U_t + c)1_{\{\xi_{t+1} > \varphi(U_t)\}}$$

# Simulação **estocástica** de um único neurônio

$$U_{t+1} = f(U_t, \xi_{t+1}) = (U_t + c)1_{\{\xi_{t+1} > \varphi(U_t)\}}$$

Suponha

- ▶  $c = 1$ ,  $U(0) = 0$ ,
- ▶  $\varphi(n) = 1 - 2^{-n}$  ( $\varphi(0) = 0$ ,  $\varphi(1) = 0.5$ ,  $\varphi(2) = 0.75$ ,  $\varphi(3) = 0.875$ ,  $\varphi(4) = 0.9375$ )
- ▶  $(\xi_t)_{t \geq 1}$  : v.a's iid com  $\xi_t \sim Unif([0, 1])$ 
  - ▶  $\xi_1 = 0.35, \xi_2 = 0.85, \xi_3 = 0.79, \xi_4 = 0.28, \xi_5 = 0.03, \dots$

# Simulação **estocástica** de um único neurônio

$$U_{t+1} = f(U_t, \xi_{t+1}) = (U_t + c)1_{\{\xi_{t+1} > \varphi(U_t)\}}$$

Suponha

- ▶  $c = 1$ ,  $U(0) = 0$ ,
- ▶  $\varphi(n) = 1 - 2^{-n}$  ( $\varphi(0) = 0$ ,  $\varphi(1) = 0.5$ ,  $\varphi(2) = 0.75$ ,  $\varphi(3) = 0.875$ ,  $\varphi(4) = 0.9375$ )
- ▶  $(\xi_t)_{t \geq 1}$  : v.a.'s iid com  $\xi_t \sim Unif([0, 1])$ 
  - ▶  $\xi_1 = 0.35, \xi_2 = 0.85, \xi_3 = 0.79, \xi_4 = 0.28, \xi_5 = 0.03, \dots$

Nesse caso

- ▶  $U_1 = (0 + 1)1_{\{0.35 > 0\}} = 1$
- ▶  $U_2 = (1 + 1)1_{\{0.85 > 0.5\}} = 2$
- ▶  $U_3 = (2 + 1)1_{\{0.79 > 0.75\}} = 3$
- ▶  $U_4 = (3 + 1)1_{\{0.28 > 0.875\}} = 0$
- ▶  $U_5 = (0 + 1)1_{\{0.03 > 0\}} = 1 \dots$

# Memória variável

Considere a cadeia estocástica  $(X_t)_{t \geq 0}$  dada por

$$X_t = 1_{\{U_t=0\}}$$



# Memória variável

Considere a cadeia estocástica  $(X_t)_{t \geq 0}$  dada por

$$X_t = 1_{\{U_t=0\}} \quad \Rightarrow \quad X_{t+1} = \begin{cases} 1, & \text{com prob } \varphi(U_t) \\ 0, & \text{com prob } 1 - \varphi(U_t) \end{cases}$$

# Memória variável

Considere a cadeia estocástica  $(X_t)_{t \geq 0}$  dada por

$$X_t = 1_{\{U_t=0\}} \quad \Rightarrow \quad X_{t+1} = \begin{cases} 1, & \text{com prob } \varphi(U_t) \\ 0, & \text{com prob } 1 - \varphi(U_t) \end{cases}$$

**Pergunta:** Como definir um algoritmo estocástico para gerar  $X_{t+1}$  a partir de  $X_t, X_{t-1}, X_{t-2}, \dots$ ?

# Memória variável

Considere a cadeia estocástica  $(X_t)_{t \geq 0}$  dada por

$$X_t = 1_{\{U_t=0\}} \quad \Rightarrow \quad X_{t+1} = \begin{cases} 1, & \text{com prob } \varphi(U_t) \\ 0, & \text{com prob } 1 - \varphi(U_t) \end{cases}$$

**Pergunta:** Como definir um algoritmo estocástico para gerar  $X_{t+1}$  a partir de  $X_t, X_{t-1}, X_{t-2}, \dots$ ?

Vejamos

►  $X_t = 1 \Rightarrow U_t = 0$

# Memória variável

Considere a cadeia estocástica  $(X_t)_{t \geq 0}$  dada por

$$X_t = 1_{\{U_t=0\}} \quad \Rightarrow \quad X_{t+1} = \begin{cases} 1, & \text{com prob } \varphi(U_t) \\ 0, & \text{com prob } 1 - \varphi(U_t) \end{cases}$$

**Pergunta:** Como definir um algoritmo estocástico para gerar  $X_{t+1}$  a partir de  $X_t, X_{t-1}, X_{t-2}, \dots$ ?

Vejamos

►  $X_t = 1 \Rightarrow U_t = 0 \Rightarrow X_{t+1} = 1$  com prob  $\varphi(0)$

# Memória variável

Considere a cadeia estocástica  $(X_t)_{t \geq 0}$  dada por

$$X_t = 1_{\{U_t=0\}} \quad \Rightarrow \quad X_{t+1} = \begin{cases} 1, & \text{com prob } \varphi(U_t) \\ 0, & \text{com prob } 1 - \varphi(U_t) \end{cases}$$

**Pergunta:** Como definir um algoritmo estocástico para gerar  $X_{t+1}$  a partir de  $X_t, X_{t-1}, X_{t-2}, \dots$ ?

Vejamos

- ▶  $X_t = 1 \Rightarrow U_t = 0 \Rightarrow X_{t+1} = 1$  com prob  $\varphi(0)$
- ▶  $X_t = 0 \Rightarrow U_t \neq 0$

# Memória variável

Considere a cadeia estocástica  $(X_t)_{t \geq 0}$  dada por

$$X_t = 1_{\{U_t=0\}} \quad \Rightarrow \quad X_{t+1} = \begin{cases} 1, & \text{com prob } \varphi(U_t) \\ 0, & \text{com prob } 1 - \varphi(U_t) \end{cases}$$

**Pergunta:** Como definir um algoritmo estocástico para gerar  $X_{t+1}$  a partir de  $X_t, X_{t-1}, X_{t-2}, \dots$ ?

Vejamos

- ▶  $X_t = 1 \Rightarrow U_t = 0 \Rightarrow X_{t+1} = 1$  com prob  $\varphi(0)$
- ▶  $X_t = 0 \Rightarrow U_t \neq 0 \Rightarrow X_{t+1} = 1$  com prob  $\varphi(?)$

# Memória variável

Considere a cadeia estocástica  $(X_t)_{t \geq 0}$  dada por

$$X_t = 1_{\{U_t=0\}} \quad \Rightarrow \quad X_{t+1} = \begin{cases} 1, & \text{com prob } \varphi(U_t) \\ 0, & \text{com prob } 1 - \varphi(U_t) \end{cases}$$

**Pergunta:** Como definir um algoritmo estocástico para gerar  $X_{t+1}$  a partir de  $X_t, X_{t-1}, X_{t-2}, \dots$ ?

Vejamos

- ▶  $X_t = 1 \Rightarrow U_t = 0 \Rightarrow X_{t+1} = 1$  com prob  $\varphi(0)$
- ▶  $X_t = 0 \Rightarrow U_t \neq 0$ 
  - ▷  $X_{t-1} = 1$

# Memória variável

Considere a cadeia estocástica  $(X_t)_{t \geq 0}$  dada por

$$X_t = 1_{\{U_t=0\}} \Rightarrow X_{t+1} = \begin{cases} 1, & \text{com prob } \varphi(U_t) \\ 0, & \text{com prob } 1 - \varphi(U_t) \end{cases}$$

**Pergunta:** Como definir um algoritmo estocástico para gerar  $X_{t+1}$  a partir de  $X_t, X_{t-1}, X_{t-2}, \dots$ ?

Vejamos

- ▶  $X_t = 1 \Rightarrow U_t = 0 \Rightarrow X_{t+1} = 1$  com prob  $\varphi(0)$
- ▶  $X_t = 0 \Rightarrow U_t \neq 0$ 
  - ▷  $X_{t-1} = 1 \Rightarrow U_{t-1} = 0$



# Memória variável

Considere a cadeia estocástica  $(X_t)_{t \geq 0}$  dada por

$$X_t = 1_{\{U_t=0\}} \Rightarrow X_{t+1} = \begin{cases} 1, & \text{com prob } \varphi(U_t) \\ 0, & \text{com prob } 1 - \varphi(U_t) \end{cases}$$

**Pergunta:** Como definir um algoritmo estocástico para gerar  $X_{t+1}$  a partir de  $X_t, X_{t-1}, X_{t-2}, \dots$ ?

Vejamos

- ▶  $X_t = 1 \Rightarrow U_t = 0 \Rightarrow X_{t+1} = 1$  com prob  $\varphi(0)$
- ▶  $X_t = 0 \Rightarrow U_t \neq 0$ 
  - ▷  $X_{t-1} = 1 \Rightarrow U_{t-1} = 0 \Rightarrow U_t = c$

# Memória variável

Considere a cadeia estocástica  $(X_t)_{t \geq 0}$  dada por

$$X_t = 1_{\{U_t=0\}} \Rightarrow X_{t+1} = \begin{cases} 1, & \text{com prob } \varphi(U_t) \\ 0, & \text{com prob } 1 - \varphi(U_t) \end{cases}$$

**Pergunta:** Como definir um algoritmo estocástico para gerar  $X_{t+1}$  a partir de  $X_t, X_{t-1}, X_{t-2}, \dots$ ?

Vejamos

- ▶  $X_t = 1 \Rightarrow U_t = 0 \Rightarrow X_{t+1} = 1$  com prob  $\varphi(0)$
- ▶  $X_t = 0 \Rightarrow U_t \neq 0$ 
  - ▷  $X_{t-1} = 1 \Rightarrow U_{t-1} = 0 \Rightarrow U_t = c \Rightarrow X_{t+1} = 1$  com prob  $\varphi(c)$

# Memória variável

Considere a cadeia estocástica  $(X_t)_{t \geq 0}$  dada por

$$X_t = 1_{\{U_t=0\}} \Rightarrow X_{t+1} = \begin{cases} 1, & \text{com prob } \varphi(U_t) \\ 0, & \text{com prob } 1 - \varphi(U_t) \end{cases}$$

**Pergunta:** Como definir um algoritmo estocástico para gerar  $X_{t+1}$  a partir de  $X_t, X_{t-1}, X_{t-2}, \dots$ ?

Vejamos

- ▶  $X_t = 1 \Rightarrow U_t = 0 \Rightarrow X_{t+1} = 1$  com prob  $\varphi(0)$
- ▶  $X_t = 0 \Rightarrow U_t \neq 0$ 
  - ▷  $X_{t-1} = 1 \Rightarrow U_{t-1} = 0 \Rightarrow U_t = c \Rightarrow X_{t+1} = 1$  com prob  $\varphi(c)$
  - ▷  $X_{t-1} = 0$

# Memória variável

Considere a cadeia estocástica  $(X_t)_{t \geq 0}$  dada por

$$X_t = 1_{\{U_t=0\}} \Rightarrow X_{t+1} = \begin{cases} 1, & \text{com prob } \varphi(U_t) \\ 0, & \text{com prob } 1 - \varphi(U_t) \end{cases}$$

**Pergunta:** Como definir um algoritmo estocástico para gerar  $X_{t+1}$  a partir de  $X_t, X_{t-1}, X_{t-2}, \dots$ ?

Vejamos

- ▶  $X_t = 1 \Rightarrow U_t = 0 \Rightarrow X_{t+1} = 1$  com prob  $\varphi(0)$
- ▶  $X_t = 0 \Rightarrow U_t \neq 0$ 
  - ▷  $X_{t-1} = 1 \Rightarrow U_{t-1} = 0 \Rightarrow U_t = c \Rightarrow X_{t+1} = 1$  com prob  $\varphi(c)$
  - ▷  $X_{t-1} = 0 \Rightarrow U_{t-1} \neq 0$

# Memória variável

Considere a cadeia estocástica  $(X_t)_{t \geq 0}$  dada por

$$X_t = 1_{\{U_t=0\}} \Rightarrow X_{t+1} = \begin{cases} 1, & \text{com prob } \varphi(U_t) \\ 0, & \text{com prob } 1 - \varphi(U_t) \end{cases}$$

**Pergunta:** Como definir um algoritmo estocástico para gerar  $X_{t+1}$  a partir de  $X_t, X_{t-1}, X_{t-2}, \dots$ ?

Vejamos

- ▶  $X_t = 1 \Rightarrow U_t = 0 \Rightarrow X_{t+1} = 1$  com prob  $\varphi(0)$
- ▶  $X_t = 0 \Rightarrow U_t \neq 0$ 
  - ▷  $X_{t-1} = 1 \Rightarrow U_{t-1} = 0 \Rightarrow U_t = c \Rightarrow X_{t+1} = 1$  com prob  $\varphi(c)$
  - ▷  $X_{t-1} = 0 \Rightarrow U_{t-1} \neq 0 \Rightarrow X_{t+1} = 1$  com prob  $\varphi(?)$

# Memória variável

Considere a cadeia estocástica  $(X_t)_{t \geq 0}$  dada por

$$X_t = 1_{\{U_t=0\}} \Rightarrow X_{t+1} = \begin{cases} 1, & \text{com prob } \varphi(U_t) \\ 0, & \text{com prob } 1 - \varphi(U_t) \end{cases}$$

**Pergunta:** Como definir um algoritmo estocástico para gerar  $X_{t+1}$  a partir de  $X_t, X_{t-1}, X_{t-2}, \dots$ ?

Vejamos

- ▶  $X_t = 1 \Rightarrow U_t = 0 \Rightarrow X_{t+1} = 1$  com prob  $\varphi(0)$
- ▶  $X_t = 0 \Rightarrow U_t \neq 0$ 
  - ▷  $X_{t-1} = 1 \Rightarrow U_{t-1} = 0 \Rightarrow U_t = c \Rightarrow X_{t+1} = 1$  com prob  $\varphi(c)$
  - ▷  $X_{t-1} = 0 \Rightarrow U_{t-1} \neq 0$ 
    - $X_{t-2} = 1$

# Memória variável

Considere a cadeia estocástica  $(X_t)_{t \geq 0}$  dada por

$$X_t = 1_{\{U_t=0\}} \Rightarrow X_{t+1} = \begin{cases} 1, & \text{com prob } \varphi(U_t) \\ 0, & \text{com prob } 1 - \varphi(U_t) \end{cases}$$

**Pergunta:** Como definir um algoritmo estocástico para gerar  $X_{t+1}$  a partir de  $X_t, X_{t-1}, X_{t-2}, \dots$ ?

Vejamos

- ▶  $X_t = 1 \Rightarrow U_t = 0 \Rightarrow X_{t+1} = 1$  com prob  $\varphi(0)$
- ▶  $X_t = 0 \Rightarrow U_t \neq 0$ 
  - ▷  $X_{t-1} = 1 \Rightarrow U_{t-1} = 0 \Rightarrow U_t = c \Rightarrow X_{t+1} = 1$  com prob  $\varphi(c)$
  - ▷  $X_{t-1} = 0 \Rightarrow U_{t-1} \neq 0$ 
    - $X_{t-2} = 1 \Rightarrow U_{t-2} = 0$

# Memória variável

Considere a cadeia estocástica  $(X_t)_{t \geq 0}$  dada por

$$X_t = 1_{\{U_t=0\}} \Rightarrow X_{t+1} = \begin{cases} 1, & \text{com prob } \varphi(U_t) \\ 0, & \text{com prob } 1 - \varphi(U_t) \end{cases}$$

**Pergunta:** Como definir um algoritmo estocástico para gerar  $X_{t+1}$  a partir de  $X_t, X_{t-1}, X_{t-2}, \dots$ ?

Vejamos

- ▶  $X_t = 1 \Rightarrow U_t = 0 \Rightarrow X_{t+1} = 1$  com prob  $\varphi(0)$
- ▶  $X_t = 0 \Rightarrow U_t \neq 0$ 
  - ▷  $X_{t-1} = 1 \Rightarrow U_{t-1} = 0 \Rightarrow U_t = c \Rightarrow X_{t+1} = 1$  com prob  $\varphi(c)$
  - ▷  $X_{t-1} = 0 \Rightarrow U_{t-1} \neq 0$ 
    - $X_{t-2} = 1 \Rightarrow U_{t-2} = 0 \Rightarrow U_{t-1} = c$



# Memória variável

Considere a cadeia estocástica  $(X_t)_{t \geq 0}$  dada por

$$X_t = 1_{\{U_t=0\}} \Rightarrow X_{t+1} = \begin{cases} 1, & \text{com prob } \varphi(U_t) \\ 0, & \text{com prob } 1 - \varphi(U_t) \end{cases}$$

**Pergunta:** Como definir um algoritmo estocástico para gerar  $X_{t+1}$  a partir de  $X_t, X_{t-1}, X_{t-2}, \dots$ ?

Vejamos

- ▶  $X_t = 1 \Rightarrow U_t = 0 \Rightarrow X_{t+1} = 1$  com prob  $\varphi(0)$
- ▶  $X_t = 0 \Rightarrow U_t \neq 0$ 
  - ▷  $X_{t-1} = 1 \Rightarrow U_{t-1} = 0 \Rightarrow U_t = c \Rightarrow X_{t+1} = 1$  com prob  $\varphi(c)$
  - ▷  $X_{t-1} = 0 \Rightarrow U_{t-1} \neq 0$ 
    - $X_{t-2} = 1 \Rightarrow U_{t-2} = 0 \Rightarrow U_{t-1} = c \Rightarrow U_t = 2c$

# Memória variável

Considere a cadeia estocástica  $(X_t)_{t \geq 0}$  dada por

$$X_t = 1_{\{U_t=0\}} \Rightarrow X_{t+1} = \begin{cases} 1, & \text{com prob } \varphi(U_t) \\ 0, & \text{com prob } 1 - \varphi(U_t) \end{cases}$$

**Pergunta:** Como definir um algoritmo estocástico para gerar  $X_{t+1}$  a partir de  $X_t, X_{t-1}, X_{t-2}, \dots$ ?

Vejamos

- ▶  $X_t = 1 \Rightarrow U_t = 0 \Rightarrow X_{t+1} = 1$  com prob  $\varphi(0)$
- ▶  $X_t = 0 \Rightarrow U_t \neq 0$ 
  - ▷  $X_{t-1} = 1 \Rightarrow U_{t-1} = 0 \Rightarrow U_t = c \Rightarrow X_{t+1} = 1$  com prob  $\varphi(c)$
  - ▷  $X_{t-1} = 0 \Rightarrow U_{t-1} \neq 0$ 
    - $X_{t-2} = 1 \Rightarrow U_{t-2} = 0 \Rightarrow U_{t-1} = c \Rightarrow U_t = 2c \Rightarrow X_{t+1} = 1$  com prob  $\varphi(2c)$

# Memória variável

Considere a cadeia estocástica  $(X_t)_{t \geq 0}$  dada por

$$X_t = 1_{\{U_t=0\}} \Rightarrow X_{t+1} = \begin{cases} 1, & \text{com prob } \varphi(U_t) \\ 0, & \text{com prob } 1 - \varphi(U_t) \end{cases}$$

**Pergunta:** Como definir um algoritmo estocástico para gerar  $X_{t+1}$  a partir de  $X_t, X_{t-1}, X_{t-2}, \dots$ ?

Vejamos

- ▶  $X_t = 1 \Rightarrow U_t = 0 \Rightarrow X_{t+1} = 1$  com prob  $\varphi(0)$
- ▶  $X_t = 0 \Rightarrow U_t \neq 0$ 
  - ▷  $X_{t-1} = 1 \Rightarrow U_{t-1} = 0 \Rightarrow U_t = c \Rightarrow X_{t+1} = 1$  com prob  $\varphi(c)$
  - ▷  $X_{t-1} = 0 \Rightarrow U_{t-1} \neq 0$ 
    - $X_{t-2} = 1 \Rightarrow U_{t-2} = 0 \Rightarrow U_{t-1} = c \Rightarrow U_t = 2c \Rightarrow X_{t+1} = 1$  com prob  $\varphi(2c)$
    - $X_{t-2} = 0 \Rightarrow U_{t-2} \neq 0 \dots$

# Memória variável

Considere a cadeia estocástica  $(X_t)_{t \geq 0}$  dada por

$$X_t = 1_{\{U_t=0\}} \Rightarrow X_{t+1} = \begin{cases} 1, & \text{com prob } \varphi(U_t) \\ 0, & \text{com prob } 1 - \varphi(U_t) \end{cases}$$

**Pergunta:** Como definir um algoritmo estocástico para gerar  $X_{t+1}$  a partir de  $X_t, X_{t-1}, X_{t-2}, \dots$ ?

Vejamos

- ▶  $X_t = 1 \Rightarrow U_t = 0 \Rightarrow X_{t+1} = 1$  com prob  $\varphi(0)$
- ▶  $X_t = 0 \Rightarrow U_t \neq 0$ 
  - ▷  $X_{t-1} = 1 \Rightarrow U_{t-1} = 0 \Rightarrow U_t = c \Rightarrow X_{t+1} = 1$  com prob  $\varphi(c)$
  - ▷  $X_{t-1} = 0 \Rightarrow U_{t-1} \neq 0$ 
    - $X_{t-2} = 1 \Rightarrow U_{t-2} = 0 \Rightarrow U_{t-1} = c \Rightarrow U_t = 2c \Rightarrow X_{t+1} = 1$  com prob  $\varphi(2c)$
    - $X_{t-2} = 0 \Rightarrow U_{t-2} \neq 0 \dots$

**Árvore de Contextos!!!!**

# Memória variável

Defina

$$L_t = L_t(X_t, X_{t-1}, \dots) = \sup\{s \leq t : X_s = 1\}$$

(a última vez que  $X$  foi igual a 1, antes do tempo  $t$ )

Assim

$$X_{t+1} = F(\xi_{t+1}, X_t, \dots, X_{L_t})$$

**Exemplo:** Suponha a seguinte realização

$$X_0 = 1, X_1 = 0, X_2 = 0, X_3 = 1, X_4 = 0, X_5 = 0, X_6 = 0$$

▶  $L_6 = 3$

▶  $X_7 = F(\xi_7, X_6, \dots, X_3)$

**Exemplo:** Suponha a seguinte realização

$$X_0 = 1, X_1 = 0, X_2 = 0, X_3 = 1, X_4 = 0, X_5 = 0, X_6 = 0$$

- ▶  $L_6 = 3$
- ▶  $X_7 = F(\xi_7, X_6, \dots, X_3)$
- ▶  $U_3 = 0, U_4 = c, U_5 = 2c$  e  $U_6 = 3c$

**Exemplo:** Suponha a seguinte realização

$$X_0 = 1, X_1 = 0, X_2 = 0, X_3 = 1, X_4 = 0, X_5 = 0, X_6 = 0$$

- ▶  $L_6 = 3$
- ▶  $X_7 = F(\xi_7, X_6, \dots, X_3)$
- ▶  $U_3 = 0, U_4 = c, U_5 = 2c$  e  $U_6 = 3c$
- ▶ Por definição

$$U_6 = \sum_{s=L_6+1}^6 c = c(6 - L_6)$$



**Exemplo:** Suponha a seguinte realização

$$X_0 = 1, X_1 = 0, X_2 = 0, X_3 = 1, X_4 = 0, X_5 = 0, X_6 = 0$$

- ▶  $L_6 = 3$
- ▶  $X_7 = F(\xi_7, X_6, \dots, X_3)$
- ▶  $U_3 = 0, U_4 = c, U_5 = 2c$  e  $U_6 = 3c$
- ▶ Por definição

$$U_6 = \sum_{s=L_6+1}^6 c = c(6 - L_6)$$

- ▶ O que implica

$$X_7 = 1 \text{ com prob } \varphi(c(6 - L_6)).$$

**Exemplo:** Suponha a seguinte realização

$$X_0 = 1, X_1 = 0, X_2 = 0, X_3 = 1, X_4 = 0, X_5 = 0, X_6 = 0$$

- ▶  $L_6 = 3$
- ▶  $X_7 = F(\xi_7, X_6, \dots, X_3)$
- ▶  $U_3 = 0, U_4 = c, U_5 = 2c$  e  $U_6 = 3c$
- ▶ Por definição

$$U_6 = \sum_{s=L_6+1}^6 c = c(6 - L_6)$$

- ▶ O que implica

$$X_7 = 1 \text{ com prob } \varphi(c(6 - L_6)).$$

- ▶ Assim,  $X_7$  pode ser escrito como

$$X_7 = 1_{\{\xi_7 < \varphi(c(6 - L_6))\}}$$

# Sistema de Neurônios Interagentes

- ▶ Cada neurônio dispara com probabilidade proporcional ao seu potencial

- ▶ Cada neurônio dispara com probabilidade proporcional ao seu potencial
- ▶ **Sinapses químicas**
  - ▶ Se um neurônio  $i$  dispara em um instante  $t$ 
    - o seu potencial é **resetado** para 0  
 $\Rightarrow U_t(i) = 0$
    - o potencial dos demais neurônios **recebe uma quantidade**  $W_{i \rightarrow j} \in \mathbb{R}$   
 $\Rightarrow \forall j \neq i, U_t(j) = U_{t-1}(j) + W_{i \rightarrow j}$  (sinapses químicas)

# Definição do modelo

- ▶  $I = \{1, 2, \dots, N\}$  - um conjunto finito de neurônios
- ▶  $(\mathbf{X}_t)_{t \geq 0}$ : cadeia estocástica tomando valores em  $\{0, 1\}^I$ ,  $\forall t \geq 0$

$$\mathbf{X}_t = (X_t(1), X_t(2), \dots, X_t(N))$$

- ▶ Para cada neurônio  $i \in I$  e cada instante de tempo  $t \geq 0$

$$X_t(i) = \begin{cases} 1, & \text{se o neurônio } i \text{ disparou no instante } t \\ 0, & \text{caso contrário} \end{cases}$$

# Definição do modelo

- ▶  $I = \{1, 2, \dots, N\}$  - um conjunto finito de neurônios
- ▶  $(\mathbf{X}_t)_{t \geq 0}$ : cadeia estocástica tomando valores em  $\{0, 1\}^I$ ,  $\forall t \geq 0$

$$\mathbf{X}_t = (X_t(1), X_t(2), \dots, X_t(N))$$

- ▶ Para cada neurônio  $i \in I$  e cada instante de tempo  $t \geq 0$

$$X_t(i) = \begin{cases} 1, & \text{se o neurônio } i \text{ disparou no instante } t \\ 0, & \text{caso contrário} \end{cases}$$

- ▶  $L_t^i = \sup\{s \leq t : X_s(i) = 1\}$ , com  $\sup\{\emptyset\} = -\infty$   
(tempo do último disparo de  $i$ )

# Definição do Modelo

Para  $t \geq 0$ , considere uma sequência  $\zeta_t = (\xi_t(1), \xi_t(2), \dots, \xi_t(N))$  de v.a's iid com distribuição uniforme em  $[0, 1]$ , para cada  $t \geq 0$

$$\mathbf{X}_{t+1} = F(\zeta_{t+1}, \mathbf{X}_t, \mathbf{X}_{t-1}, \dots, \mathbf{X}_0)$$

Onde  $F$  é tal que

$$\begin{aligned} X_{t+1} &= F_i(\xi_{t+1}(i), X_t(1), X_{t-1}(i), \dots, X_{L_t^i}(i)) \\ &= 1_{\{\xi_{t+1}(i) \leq \varphi(U_i(t))\}} \\ &= 1_{\{\xi_{t+1}(i) \leq \varphi(\sum_{s=L_t^i+1}^t C_s(i))\}} \end{aligned}$$



# Definição do Modelo

Para  $t \geq 0$ , considere uma sequência  $\zeta_t = (\xi_t(1), \xi_t(2), \dots, \xi_t(N))$  de v.a's iid com distribuição uniforme em  $[0, 1]$ , para cada  $t \geq 0$

$$\mathbf{X}_{t+1} = F(\zeta_{t+1}, \mathbf{X}_t, \mathbf{X}_{t-1}, \dots, \mathbf{X}_0)$$

Onde  $F$  é tal que

$$\begin{aligned} X_{t+1} &= F_i(\xi_{t+1}(i), X_t(1), X_{t-1}(i), \dots, X_{L_t^i}(i)) \\ &= 1_{\{\xi_{t+1}(i) \leq \varphi(U_i(t))\}} \\ &= 1_{\{\xi_{t+1}(i) \leq \varphi(\sum_{s=L_t^i+1}^t C_s(i))\}} \end{aligned}$$

$$U_t(i) = \sum_{s=L_t^i+1}^t C_s(i) : \text{potencial do neurônio } i \text{ no tempo } t$$

# Definição do Modelo

Para  $t \geq 0$ , considere uma sequência  $\zeta_t = (\xi_t(1), \xi_t(2), \dots, \xi_t(N))$  de v.a's iid com distribuição uniforme em  $[0, 1]$ , para cada  $t \geq 0$

$$\mathbf{X}_{t+1} = F(\zeta_{t+1}, \mathbf{X}_t, \mathbf{X}_{t-1}, \dots, \mathbf{X}_0)$$

Onde  $F$  é tal que

$$\begin{aligned} X_{t+1} &= F_i(\xi_{t+1}(i), X_t(1), X_{t-1}(i), \dots, X_{L_t^i}(i)) \\ &= 1_{\{\xi_{t+1}(i) \leq \varphi(U_i(t))\}} \\ &= 1_{\{\xi_{t+1}(i) \leq \varphi(\sum_{s=L_t^i+1}^t C_s(i))\}} \end{aligned}$$

$$U_t(i) = \sum_{s=L_t^i+1}^t C_s(i) : \text{potencial do neurônio } i \text{ no tempo } t$$

**Mas quem é a corrente estímulo  $C_t(i)$ ?**

# Definindo a corrente estímulo

- ▶  $C_t(i)$  não é mais constante!!!!
- ▶  $C_t(i)$  agora **modela a interação com outros neurônios!**

# Definindo a corrente estímulo

- ▶  $C_t(i)$  não é mais constante!!!!
- ▶  $C_t(i)$  agora **modela a interação com outros neurônios!**

$$C_t(i) = \sum_{j \neq i} X_t(j), \quad t \geq 0$$

- ▶ Se  $j$  dispara no tempo  $t \geq 0 \Rightarrow X_t(j) = 1$ ,  
 $\Rightarrow C_t(i)$  recebe 1

# Definindo a corrente estímulo

- ▶  $C_t(i)$  não é mais constante!!!!
- ▶  $C_t(i)$  agora **modela a interação com outros neurônios!**
  - ▶ Sinapses químicas:  $W_{j \rightarrow i} \in \mathbb{R}$  para  $j \neq i$  e  $W_{i \rightarrow i} = 0$

$$C_t(i) = \sum_{j \neq i} W_{j \rightarrow i} X_t(j), \quad t \geq 0$$

- ▶ Se  $j$  dispara no tempo  $t \geq 0 \Rightarrow X_t(j) = 1$ ,  
 $\Rightarrow C_t(i)$  recebe  $W_{j \rightarrow i}$

# Definição do Modelo

Portanto

$$\begin{aligned}X_{t+1} &= F_i(\xi_{t+1}(i), X_t(1), X_{t-1}(i), \dots, X_{L_t^i}(i)) \\&= 1_{\{\xi_{t+1}(i) \leq \varphi(U_i(t))\}} \\&= 1_{\{\xi_{t+1}(i) \leq \varphi(\sum_{s=L_t^i+1}^t c_s(i))\}}\end{aligned}$$

# Definição do Modelo

Portanto

$$\begin{aligned}X_{t+1} &= F_i(\xi_{t+1}(i), X_t(1), X_{t-1}(i), \dots, X_{L_t^i}(i)) \\&= 1_{\{\xi_{t+1}(i) \leq \varphi(U_i(t))\}} \\&= 1_{\{\xi_{t+1}(i) \leq \varphi(\sum_{s=L_t^i+1}^t c_s(i))\}} \\&= 1_{\{\xi_{t+1}(i) \leq \varphi\left(\sum_{s=L_t^i+1}^t \sum_{j \neq i} w_{j \rightarrow i} X_s(j)\right)\}}\end{aligned}$$

# Definição do Modelo

Portanto

$$\begin{aligned}X_{t+1} &= F_i(\xi_{t+1}(i), X_t(1), X_{t-1}(i), \dots, X_{L_t^i}(i)) \\&= 1_{\{\xi_{t+1}(i) \leq \varphi(U_i(t))\}} \\&= 1_{\{\xi_{t+1}(i) \leq \varphi(\sum_{s=L_t^i+1}^t C_s(i))\}} \\&= 1_{\{\xi_{t+1}(i) \leq \varphi\left(\sum_{s=L_t^i+1}^t \sum_{j \neq i} w_{j \rightarrow i} X_s(j)\right)\}} \\&= 1_{\{\xi_{t+1}(i) \leq \varphi\left(\sum_{j \neq i} w_{j \rightarrow i} \sum_{s=L_t^i+1}^t X_s(j)\right)\}}\end{aligned}$$



# Definição do Modelo


Portanto

$$\begin{aligned}X_{t+1} &= F_i(\xi_{t+1}(i), X_t(1), X_{t-1}(i), \dots, X_{L_t^i}(i)) \\&= 1_{\{\xi_{t+1}(i) \leq \varphi(U_t(i))\}} \\&= 1_{\{\xi_{t+1}(i) \leq \varphi(\sum_{s=L_t^i+1}^t C_s(i))\}} \\&= 1_{\{\xi_{t+1}(i) \leq \varphi(\sum_{s=L_t^i+1}^t \sum_{j \neq i} w_{j \rightarrow i} X_s(j))\}} \\&= 1_{\{\xi_{t+1}(i) \leq \varphi(\sum_{j \neq i} w_{j \rightarrow i} \sum_{s=L_t^i+1}^t X_s(j))\}}\end{aligned}$$


$\Rightarrow X_{t+1} = 1$  com probabilidade  $\varphi(U_t(i))$  com

$$U_t(i) = \sum_{j \neq i} w_{j \rightarrow i} \sum_{s=L_t^i+1}^t X_s(j)$$

# Probabilidade de disparo: sinapses químicas




# Probabilidade de disparo: sinapses químicas



$$\mathbb{P}(X_6(1) \mid \text{passado}) = \varphi \left( \begin{array}{l} \text{disparos de 2 e 3 desde o} \\ \text{tempo de último disparo de 1} \end{array} \right)$$


# Probabilidade de disparo: sinapses químicas



$$\mathbb{P}(X_6(1) \mid \text{passado}) = \varphi \left( \begin{array}{l} \text{disparos de 2 e 3 desde o} \\ \text{tempo de último disparo de 1} \end{array} \right)$$


$$\mathbb{P}(X_6(1) = 1 \mid \text{passado}) = \varphi(\textcolor{red}{W}_{2 \rightarrow 1} + 0)$$

# Probabilidade de disparo: sinapses químicas



$$\mathbb{P}(X_6(2) \mid \text{passado}) = \varphi \left( \begin{array}{l} \text{disparos de 1 e 3 desde o} \\ \text{tempo de último disparo de 2} \end{array} \right)$$


# Probabilidade de disparo: sinapses químicas



$$\mathbb{P}(X_6(2) \mid \text{passado}) = \varphi \left( \begin{array}{l} \text{disparos de 1 e 3 desde o} \\ \text{tempo de último disparo de 2} \end{array} \right)$$


$$\mathbb{P}(X_6(2) = 1 \mid \text{passado}) = \varphi(0)$$

# Probabilidade de disparo: sinapses químicas



$$\mathbb{P}(X_6(3) \mid \text{passado}) = \varphi \left( \begin{array}{l} \text{disparos de 1 e 2 desde o} \\ \text{tempo de último disparo de 3} \end{array} \right)$$

# Probabilidade de disparo: sinapses químicas



$$\mathbb{P}(X_6(3) \mid \text{passado}) = \varphi \left( \begin{array}{l} \text{disparos de 1 e 2 desde o} \\ \text{tempo de último disparo de 3} \end{array} \right)$$

$$\mathbb{P}(X_6(3) = 1 \mid \text{passado}) = \varphi(W_{1 \rightarrow 3} + W_{2 \rightarrow 3} + 0)$$



## ► Canais de vazamento

- Cada neurônio perde continuamente potencial para o meio

## ► Canais de vazamento

- ▶ Cada neurônio perde continuamente potencial para o meio
- ▶ Sinapses que ocorreram a pouco tempo tem maior influência

## ► Canais de vazamento

- Cada neurônio perde continuamente potencial para o meio
- Sinapses que ocorreram a pouco tempo tem maior influência
- Os canais de vazamento são descritos através de uma sequência decrescente  $1, \rho, \rho^2, \rho^3, \dots$  com  $\rho \in [0, 1]$

# Potencial de membrana com vazamento

- ▶ Sinapses químicas:  $W_{j \rightarrow i} \in \mathbb{R}$  para  $j \neq i$  e  $W_{i \rightarrow i} = 0$

$$U_t(i) = \sum_{j \neq i} W_{j \rightarrow i} \sum_{s=L_t^i+1}^t X_s(j), \quad t \geq 0$$

- ▶ Se  $j$  disparou no tempo  $L_t^i + 1 \leq s \leq t \Rightarrow X_s(j) = 1$ ,  
 $\Rightarrow U_t(i)$  recebe  $W_{j \rightarrow i}$


# Potencial de membrana com vazamento

- ▶ Sinapses químicas:  $W_{j \rightarrow i} \in \mathbb{R}$  para  $j \neq i$  e  $W_{i \rightarrow i} = 0$
- ▶ Os canais de vazamento:  $1, \rho, \rho^2, \rho^3, \dots, \rho \in [0, 1]$


$$U_t(i) = \sum_{j \neq i} W_{j \rightarrow i} \sum_{s=L_t^i+1}^t \rho^{t-s} X_s(j), \quad t \geq 0$$

- ▶ Se  $j$  disparou no tempo  $L_t^i + 1 \leq s \leq t \Rightarrow X_s(j) = 1$ ,  
 $\Rightarrow U_t(i)$  recebe  $\rho^{t-s} W_{j \rightarrow i}$

# Probabilidade de disparo: COM canais de vazamento




# Probabilidade de disparo: COM canais de vazamento



$$P(X_6(1) \mid \text{passado}) = \varphi \left( \begin{array}{l} \text{disparos de 2 e 3 desde o} \\ \text{tempo de último disparo de 1} \\ \text{ponderados vazamento} \end{array} \right)$$

# Probabilidade de disparo: COM canais de vazamento




$$P(X_6(1) \mid \text{passado}) = \varphi \left( \begin{array}{l} \text{disparos de 2 e 3 desde o} \\ \text{tempo de \u00faltimo disparo de 1} \\ \text{ponderados vazamento} \end{array} \right)$$

$$P(X_6(1) \mid \text{passado}) = \varphi(\rho W_{2 \rightarrow 1} + 0)$$




# Probabilidade de disparo: COM canais de vazamento



$$\mathbb{P}(X_6(2) \mid \text{passado}) = \varphi \left( \begin{array}{l} \text{disparos de 1 e 3 desde o} \\ \text{tempo de último disparo de 2} \\ \text{ponderados vazamento} \end{array} \right)$$


# Probabilidade de disparo: COM canais de vazamento



$$\mathbb{P}(X_6(2) \mid \text{passado}) = \varphi \left( \begin{array}{l} \text{disparos de 1 e 3 desde o} \\ \text{tempo de último disparo de 2} \\ \text{ponderados vazamento} \end{array} \right)$$


$$P(X_6(2) \mid \text{passado}) = \varphi(0)$$

# Probabilidade de disparo: COM canais de vazamento



$$\mathbb{P}(X_6(3) \mid \text{passado}) = \varphi \left( \begin{array}{l} \text{disparos de 1 e 2 desde o} \\ \text{tempo de último disparo de 3} \\ \text{ponderados vazamento} \end{array} \right)$$

# Probabilidade de disparo: COM canais de vazamento



$$\mathbb{P}(X_6(3) \mid \text{passado}) = \varphi \left( \begin{array}{c} \text{disparos de 1 e 2 desde o} \\ \text{tempo de \acute{u}ltimo disparo de 3} \\ \text{ponderados vazamento} \end{array} \right)$$

$$\mathbb{P}(X_6(3) \mid \text{passado}) = \varphi(\rho^2 W_{1 \rightarrow 3} + \rho W_{2 \rightarrow 3} + 0)$$

# A cadeia dos potenciais é Markov

Suponha que  $i$  dispara no tempo  $\ell$

►  $U_\ell(i) = 0$

# A cadeia dos potenciais é Markov

Suponha que  $i$  dispara no tempo  $\ell$

►  $U_\ell(i) = 0$

►  $U_{\ell+1}(i) = \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+1}(j)$

# A cadeia dos potenciais é Markov

Suponha que  $i$  dispara no tempo  $\ell$

►  $U_\ell(i) = 0$

►  $U_{\ell+1}(i) = \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+1}(j)$

► 
$$\begin{aligned} U_{\ell+2}(i) &= \sum_{j \neq i} W_{j \rightarrow i} (\rho X_{\ell+1}(j) + X_{\ell+2}(j)) \\ &= \rho \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+1}(j) + \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+2}(j) \end{aligned}$$

# A cadeia dos potenciais é Markov

Suponha que  $i$  dispara no tempo  $\ell$

►  $U_\ell(i) = 0$

►  $U_{\ell+1}(i) = \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+1}(j)$

► 
$$\begin{aligned} U_{\ell+2}(i) &= \sum_{j \neq i} W_{j \rightarrow i} (\rho X_{\ell+1}(j) + X_{\ell+2}(j)) \\ &= \rho \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+1}(j) + \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+2}(j) \\ &= \rho U_{\ell+1}(i) + \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+2}(j) \end{aligned}$$



# A cadeia dos potenciais é Markov

Suponha que  $i$  dispara no tempo  $\ell$

$$\blacktriangleright U_\ell(i) = 0$$

$$\blacktriangleright U_{\ell+1}(i) = \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+1}(j)$$

$$\begin{aligned}\blacktriangleright U_{\ell+2}(i) &= \sum_{j \neq i} W_{j \rightarrow i} (\rho X_{\ell+1}(j) + X_{\ell+2}(j)) \\ &= \rho \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+1}(j) + \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+2}(j) \\ &= \rho U_{\ell+1}(i) + \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+2}(j)\end{aligned}$$

$$\begin{aligned}\blacktriangleright U_{\ell+3}(i) &= \sum_{j \neq i} W_{j \rightarrow i} (\rho^2 X_{\ell+1}(j) + \rho X_{\ell+2}(j) + X_{\ell+3}(j)) \\ &= \rho U_{\ell+2}(i) + \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+3}(j)\end{aligned}$$

# A cadeia dos potenciais é Markov

Suponha que  $i$  dispara no tempo  $\ell$

- ▶  $U_\ell(i) = 0$
- ▶  $U_{\ell+1}(i) = \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+1}(j)$
- ▶ 
$$\begin{aligned} U_{\ell+2}(i) &= \sum_{j \neq i} W_{j \rightarrow i} (\rho X_{\ell+1}(j) + X_{\ell+2}(j)) \\ &= \rho \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+1}(j) + \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+2}(j) \\ &= \rho U_{\ell+1}(i) + \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+2}(j) \end{aligned}$$
- ▶ 
$$\begin{aligned} U_{\ell+3}(i) &= \sum_{j \neq i} W_{j \rightarrow i} (\rho^2 X_{\ell+1}(j) + \rho X_{\ell+2}(j) + X_{\ell+3}(j)) \\ &= \rho U_{\ell+2}(i) + \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+3}(j) \end{aligned}$$

$$U_k(i) = \rho U_{k-1}(i) + \sum_{j \neq i} W_{j \rightarrow i} X_k(j)$$


# A cadeia dos potenciais é Markov

Suponha que  $i$  dispara no tempo  $\ell$


- ▶  $U_\ell(i) = 0$
- ▶  $U_{\ell+1}(i) = \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+1}(j)$
- ▶ 
$$\begin{aligned} U_{\ell+2}(i) &= \sum_{j \neq i} W_{j \rightarrow i} (\rho X_{\ell+1}(j) + X_{\ell+2}(j)) \\ &= \rho \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+1}(j) + \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+2}(j) \\ &= \rho U_{\ell+1}(i) + \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+2}(j) \end{aligned}$$
- ▶ 
$$\begin{aligned} U_{\ell+3}(i) &= \sum_{j \neq i} W_{j \rightarrow i} (\rho^2 X_{\ell+1}(j) + \rho X_{\ell+2}(j) + X_{\ell+3}(j)) \\ &= \rho U_{\ell+2}(i) + \sum_{j \neq i} W_{j \rightarrow i} X_{\ell+3}(j) \end{aligned}$$

$$U_k(i) = \rho U_{k-1}(i) + \sum_{j \neq i} W_{j \rightarrow i} 1_{\{\xi_k(j) \leq \varphi(U_{k-1}(j))\}}$$

# Evolução do potencial




# Evolução do potencial




$$P(X_6(1) = 1 | \text{passado}) = \varphi(\rho W_{2 \rightarrow 1} + 0)$$

# Evolução do potencial



$$P(X_6(1) = 1 | \text{passado}) = \varphi(\rho W_{2 \rightarrow 1} + 0)$$


# Evolução do potencial



$$P(X_6(1) = 1 | \text{passado}) = \varphi(\rho W_{2 \rightarrow 1} + 0)$$

$$P(X_7(1) = 1 | \text{passado}) = \varphi(\rho^2 W_{2 \rightarrow 1} + 0 + (W_{2 \rightarrow 1} + W_{3 \rightarrow 1}))$$

# Evolução do potencial




$$P(X_6(1) = 1 | \text{passado}) = \varphi(\rho W_{2 \rightarrow 1} + 0)$$

$$P(X_7(1) = 1 | \text{passado}) = \varphi(\rho^2 W_{2 \rightarrow 1} + 0 + (W_{2 \rightarrow 1} + W_{3 \rightarrow 1}))$$



# Evolução do potencial



$$P(X_6(1) = 1 | \text{passado}) = \varphi(\rho W_{2 \rightarrow 1} + 0)$$

$$P(X_7(1) = 1 | \text{passado}) = \varphi(\rho^2 W_{2 \rightarrow 1} + 0 + (W_{2 \rightarrow 1} + W_{3 \rightarrow 1}))$$

$$P(X_8(1) = 1 | \text{passado}) = \varphi(\rho^3 W_{2 \rightarrow 1} + 0 + \rho(W_{2 \rightarrow 1} + W_{3 \rightarrow 1}) + 0)$$

# Evolução do potencial


3	0	1	0	0	0	1	0	1		
2	0	0	0	1	0	1	0	0		
1	1	0	1	0	0	0	0	1		
	1	2	3	4	5	6	7	8	9	10

$$P(X_6(1) = 1 | \text{passado}) = \varphi(\rho W_{2 \rightarrow 1} + 0)$$

$$P(X_7(1) = 1 | \text{passado}) = \varphi(\rho^2 W_{2 \rightarrow 1} + 0 + (W_{2 \rightarrow 1} + W_{3 \rightarrow 1}))$$

$$P(X_8(1) = 1 | \text{passado}) = \varphi(\rho^3 W_{2 \rightarrow 1} + 0 + \rho(W_{2 \rightarrow 1} + W_{3 \rightarrow 1}) + 0)$$

# Evolução do potencial



$$P(X_6(1) = 1 | \text{passado}) = \varphi(\rho W_{2 \rightarrow 1} + 0)$$

$$P(X_7(1) = 1 | \text{passado}) = \varphi(\rho^2 W_{2 \rightarrow 1} + 0 + (W_{2 \rightarrow 1} + W_{3 \rightarrow 1}))$$

$$P(X_8(1) = 1 | \text{passado}) = \varphi(\rho^3 W_{2 \rightarrow 1} + 0 + \rho(W_{2 \rightarrow 1} + W_{3 \rightarrow 1}) + 0)$$

$$P(X_9(1) = 1 | \text{passado}) = \varphi(0)$$

# Evolução do potencial

3	0	1	0	0	0	1	0	1	1	
2	0	0	0	1	0	1	0	0	1	
1	1	0	1	0	0	0	0	1	0	
	1	2	3	4	5	6	7	8	9	10


$$P(X_6(1) = 1 | \text{passado}) = \varphi(\rho W_{2 \rightarrow 1} + 0)$$

$$P(X_7(1) = 1 | \text{passado}) = \varphi(\rho^2 W_{2 \rightarrow 1} + 0 + (W_{2 \rightarrow 1} + W_{3 \rightarrow 1}))$$

$$P(X_8(1) = 1 | \text{passado}) = \varphi(\rho^3 W_{2 \rightarrow 1} + 0 + \rho(W_{2 \rightarrow 1} + W_{3 \rightarrow 1}) + 0)$$

$$P(X_9(1) = 1 | \text{passado}) = \varphi(0)$$

# Evolução do potencial



$$P(X_6(1) = 1 | \text{passado}) = \varphi(\rho W_{2 \rightarrow 1} + 0)$$

$$P(X_7(1) = 1 | \text{passado}) = \varphi(\rho^2 W_{2 \rightarrow 1} + 0 + (W_{2 \rightarrow 1} + W_{3 \rightarrow 1}))$$

$$P(X_8(1) = 1 | \text{passado}) = \varphi(\rho^3 W_{2 \rightarrow 1} + 0 + \rho(W_{2 \rightarrow 1} + W_{3 \rightarrow 1}) + 0)$$

$$P(X_9(1) = 1 | \text{passado}) = \varphi(0)$$

$$P(X_{10}(1) = 1 | \text{passado}) = \varphi(W_{2 \rightarrow 1} + W_{3 \rightarrow 1})$$

# Evolução do potencial

3	0	1	0	0	0	1	0	1	1	0
2	0	0	0	1	0	1	0	0	1	1
1	1	0	1	0	0	0	0	1	0	0
	1	2	3	4	5	6	7	8	9	10

$$P(X_6(1) = 1 | \text{passado}) = \varphi(\rho W_{2 \rightarrow 1} + 0)$$

$$P(X_7(1) = 1 | \text{passado}) = \varphi(\rho^2 W_{2 \rightarrow 1} + 0 + (W_{2 \rightarrow 1} + W_{3 \rightarrow 1}))$$

$$P(X_8(1) = 1 | \text{passado}) = \varphi(\rho^3 W_{2 \rightarrow 1} + 0 + \rho(W_{2 \rightarrow 1} + W_{3 \rightarrow 1}) + 0)$$

$$P(X_9(1) = 1 | \text{passado}) = \varphi(0)$$

$$P(X_{10}(1) = 1 | \text{passado}) = \varphi(W_{2 \rightarrow 1} + W_{3 \rightarrow 1})$$

# Definição do Modelo

Para cada  $t \in \mathbb{Z}$

$$\mathcal{F}_t := \sigma(X_s(j), s \leq t, j \in I) = \left\{ \begin{array}{l} \text{a história de todo sistema} \\ \text{até o tempo } t \end{array} \right\}$$

Para cada conjunto  $F \subset I$  e configuração  $a(i) \in \{0, 1\}, i \in F$ ,

$$P(X_{t+1}(i) = a(i), i \in F | \mathcal{F}_t) = \prod_{i \in F} P(X_{t+1}(i) = a(i) | \mathcal{F}_t)$$

onde

$$P(X_{t+1}(i) = 1 | \mathcal{F}_t) = \begin{cases} \varphi_i(0), & \text{se } L_t^i = t \\ \varphi_i\left(\sum_{j \in I} W_{j \rightarrow i} \sum_{s=L_t^i+1}^t \rho^{t-s} X_s(j)\right), & \text{se } L_t^i \leq t-1 \end{cases}$$

# Sobre o modelo

- ▶ Introduzido em A.Galves e E. Löcherbach (2013).
- ▶ Para cada  $i$ , a cadeia  $(X_t(i))_{t \in \mathbb{Z}}$  esquece o passado a cada tempo de disparo.
- ▶ A cadeia  $(X_t(i))_{t \in \mathbb{Z}}$  pode ser vista como uma **cadeia estocástica com memória de alcance variável**.
- ▶ A probabilidade de disparo do neurônio  $i$  depende da atividade do sistema desde o seu tempo de último disparo.
- ▶ O modelo é um **sistema de cadeias com memória de alcance variável interagentes**.



Basta garantir que, para cada  $i \in I$  e cada  $t \geq 0$ ,

$$L_t^i < \infty \quad \text{e} \quad U_t(i) = \sum_{j \in I} W_{j \rightarrow i} \sum_{s=L_t^i+1}^t X_s(j) < \infty$$

► Lembre que  $I$  pode ser infinito

## Hipóteses H1

1.  $\forall i \in I, L_t^i < \infty$
2.  $\sup_{i \in I} \sum_{j \in I} |W_{j \rightarrow i}| < \infty$

Sob **H1** a cadeia estocástica  $(\mathbf{X}_t)_{t \leq 0}$  esta bem definida

# Grafo de interação entre os neurônio

## THE STRUCTURE OF THE NERVOUS SYSTEM OF THE NEMATODE *CAENORHABDITIS ELEGANS*

BY J. G. WHITE, E. SOUTHGATE, J. N. THOMSON

AND S. BRENNER, F.R.S.

*Laboratory of Molecular Biology, Medical Research Council Centre, Hills Road,  
Cambridge CB2 2QH, U.K.*

► Mapeamento completo da rede neural de um *Caenorhabditis elegans*

► [wormweb.org](http://wormweb.org)

# A vizinhança/grrafo de interação

Os pesos sinápticos induzem um **grafo orientado**

- ▶ O conjunto de neurônios são os vértices.
- ▶ Dados dois neurônios  $i$  e  $j$  se  $W_{i \rightarrow j} \neq 0$  então a aresta  $i \rightarrow j$  pertence ao grafo.

# A vizinhança/grrafo de interação

Os pesos sinápticos induzem um **grafo orientado**

- ▶ O conjunto de neurônios são os vértices.
- ▶ Dados dois neurônios  $i$  e  $j$  se  $W_{i \rightarrow j} \neq 0$  então a aresta  $i \rightarrow j$  pertence ao grafo.

**Pergunta:** É possível recuperar o grafo de interações a partir de amostras cadeia **X**?

# A vizinhança/grrafo de interação

Os pesos sinápticos induzem um **grafo orientado**

- ▶ O conjunto de neurônios são os vértices.
- ▶ Dados dois neurônios  $i$  e  $j$  se  $W_{i \rightarrow j} \neq 0$  então a aresta  $i \rightarrow j$  pertence ao grafo.

**Pergunta:** É possível recuperar o grafo de interações a partir de amostras cadeia **X**?

**Resposta:** Sim.

# Reformulando o problema

Fixado um neurônio  $i$ , vamos recuperar a *vizinhança de interação* de  $i$ .

O conjunto dos neurônios  
cujos disparos afetam o  
potencial de membrana de  $i$ .

$$V_{\rightarrow i} = \{j \in I : W_{j \rightarrow i} \neq 0\}$$

# Reformulando o problema

Fixado um neurônio  $i$ , vamos recuperar a *vizinhança de interação* de  $i$ .

O conjunto dos neurônios  
cujos disparos afetam o  
potencial de membrana de  $i$ .

$$V_{\rightarrow i} = \{j \in I : W_{j \rightarrow i} \neq 0\}$$

Estimar o grafo de interação entre os neurônios



Estimar a vizinhança de interação de cada neurônio.



# Ideia (ignorando os canais de vazamento)

$$P \left( X(i) = 1 \mid \begin{array}{c} \begin{array}{c} j \\ \begin{array}{|c|c|c|c|} \hline 0 & 0 & 1 & 0 \\ \hline 0 & 1 & 1 & 0 \\ \hline 1 & 0 & 1 & 0 \\ \hline 0 & 0 & 0 & 1 \\ \hline 0 & 1 & 0 & 0 \\ \hline i & 1 & 0 & 0 & 0 & 0 \\ \hline \end{array} \end{array} \right)$$

# Ideia (ignorando os canais de vazamento)

$$P \left( X(i) = 1 \mid \begin{array}{c} \begin{array}{|c|c|c|c|} \hline 0 & 0 & 1 & 0 \\ \hline 0 & 1 & 1 & 0 \\ \hline 1 & 0 & 1 & 0 \\ \hline 0 & 0 & 0 & 1 \\ \hline 0 & 1 & 0 & 0 \\ \hline \end{array} \\ i \begin{array}{|c|c|c|c|c|} \hline 1 & 0 & 0 & 0 & 0 \\ \hline \end{array} \end{array} \right)$$

$= \varphi \left( W_{\cdot \rightarrow i} \# \text{ 1's amarelos} + W_{j \rightarrow i} \# \text{ 1's vermelhos} \right)$

# Ideia (ignorando os canais de vazamento)

$$P \left( X(i) = 1 \mid \begin{array}{c} \begin{array}{|c|c|c|c|} \hline 0 & 0 & 1 & 0 \\ \hline \end{array} \\ \begin{array}{|c|c|c|c|} \hline 0 & 1 & 0 & 1 \\ \hline \end{array} \\ \begin{array}{|c|c|c|c|} \hline 1 & 0 & 1 & 0 \\ \hline \end{array} \\ \begin{array}{|c|c|c|c|} \hline 0 & 0 & 0 & 1 \\ \hline \end{array} \\ \begin{array}{|c|c|c|c|} \hline 0 & 1 & 0 & 0 \\ \hline \end{array} \\ \begin{array}{|c|c|c|c|c|} \hline 1 & 0 & 0 & 0 & 0 \\ \hline \end{array} \end{array} \right)$$

$= \varphi \left( W_{\cdot \rightarrow i} \# \text{ 1's amarelos} + W_{j \rightarrow i} \# \text{ 1's vermelhos} \right)$

# Ideia (ignorando os canais de vazamento)

$$P \left( X(i) = 1 \mid \begin{array}{c} \begin{array}{|c|c|c|c|} \hline 0 & 0 & 1 & 0 \\ \hline 0 & 0 & 0 & 0 \\ \hline 1 & 0 & 1 & 0 \\ \hline 0 & 0 & 0 & 1 \\ \hline 0 & 1 & 0 & 0 \\ \hline \end{array} \\ i \begin{array}{|c|c|c|c|c|} \hline 1 & 0 & 0 & 0 & 0 \\ \hline \end{array} \end{array} \right)$$

$= \varphi \left( W_{\cdot \rightarrow i} \# \text{ 1's amarelos} + W_{j \rightarrow i} \# \text{ 1's vermelhos} \right)$

# Ideia (ignorando os canais de vazamento)

$$P \left( X(i) = 1 \mid \begin{array}{c} \begin{array}{c} \begin{array}{ccccc} 0 & 0 & 1 & 0 \\ 1 & 1 & 1 & 1 \\ 1 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \end{array} \\ \begin{array}{ccccc} i & 1 & 0 & 0 & 0 \end{array} \end{array} \right) \\ = \varphi \left( W_{\cdot \rightarrow i} \# \text{ 1's amarelos } + W_{j \rightarrow i} \# \text{ 1's vermelhos } \right)$$

## Ideia (ignorando os canais de vazamento)

$$P \left( X(i) = 1 \mid \begin{array}{c} \begin{array}{|c|c|c|c|} \hline 0 & 0 & 1 & 0 \\ \hline \end{array} \\ \begin{array}{|c|c|c|c|} \hline 1 & 1 & 1 & 1 \\ \hline \end{array} \\ \begin{array}{|c|c|c|c|} \hline 1 & 0 & 1 & 0 \\ \hline \end{array} \\ \begin{array}{|c|c|c|c|} \hline 0 & 0 & 0 & 1 \\ \hline \end{array} \\ \begin{array}{|c|c|c|c|} \hline 0 & 1 & 0 & 0 \\ \hline \end{array} \\ \begin{array}{|c|c|c|c|c|} \hline 1 & 0 & 0 & 0 & 0 \\ \hline \end{array} \end{array} \right)$$

*j*

$$= \varphi \left( W_{\cdot \rightarrow i} \# \text{ 1's amarelos } + W_{j \rightarrow i} \# \text{ 1's vermelhos } \right)$$


### Conclusão:

$\varphi$  estritamente crescente  $\implies P(X_t(i) = 1 \mid \text{bloco})$

é sensível a mudanças na realizações de  $j$ .

# Exemplo

Se  $W_{j \rightarrow i} = 0$ , então



$$P(X(i) = 1 \mid w)$$

$$= P(W_{\rightarrow i} \# \text{ 1's amarelos} + 0 \# \text{ 1's de } j)$$

$$= P(X(i) = 1 \mid v)$$

# Exemplo

Se  $W_{j \rightarrow i} = 0$ , então

	$w$					
	=					
$j$	0	1	1	0	0	
	=					
	1	0	0	0	0	0

	$v$					
	=					
$j$	1	1	0	0	1	
	=					
	1	0	0	0	0	0

$$P(X(i) = 1 \mid w)$$

$$= P(W_{\cdot \rightarrow i} \# \text{ 1's amarelos} + 0 \# \text{ 1's de } j)$$

$$= P(X(i) = 1 \mid v)$$

Não conhecemos as probabilidades!!



# Exemplo

Se  $W_{j \rightarrow i} = 0$ , então

	$w$					
	=					
$j$	0	1	1	0	0	
	=					
	1	0	0	0	0	0

	$v$					
	=					
$j$	1	1	0	0	1	
	=					
	1	0	0	0	0	0

$$P(X(i) = 1 \mid w)$$

$$= P(W_{\rightarrow i} \# \text{ 1's amarelos} + 0 \# \text{ 1's de } j)$$

$$= P(X(i) = 1 \mid v)$$

Não conhecemos as probabilidades!!

Mas conhecemos os instantes de disparos!!

Considere o número de vezes que uma configuração/bloco  $w$  acontece numa amostra de tamanho  $n$

$$N_n^i(\begin{array}{|c|} \hline \begin{array}{|c|c|c|c|c|c|} \hline & & w & & & \\ \hline \end{array} \\ \hline \end{array})$$

The diagram shows a 6x6 grid with a red 'w' in the center. Below the grid is a row of six boxes containing the values 1, 0, 0, 0, 0, 0.

Considere o número de vezes que uma configuração/bloco  $w$  acontece numa amostra de tamanho  $n$  seguido por um disparo de  $i$

$$N_n^i(\text{grid with } w \text{ and } 100001)$$

# Teorema

Quando o tamanho da amostra  $n$  cresce para o infinito

$$\hat{p}_i(1|v) = \frac{N_n^i \left( \begin{array}{|c|} \hline \begin{array}{c} \text{Grid with } v \end{array} \\ \hline \begin{array}{|c|c|c|c|c|c|} \hline 1 & 0 & 0 & 0 & 0 & 0 & 1 \end{array} \\ \hline \end{array} \right)}{N_n^i \left( \begin{array}{|c|} \hline \begin{array}{c} \text{Grid with } v \end{array} \\ \hline \begin{array}{|c|c|c|c|c|c|} \hline 1 & 0 & 0 & 0 & 0 & 0 \end{array} \\ \hline \end{array} \right)} \longrightarrow P(X(i) = 1|v)$$

- ▶ Se a sensibilidade de  $\hat{p}$  em relação a mudanças nos disparos de  $j$  é “pequena”, consideramos que  $j$  não influencia  $i$

# Estimador

► Se a sensibilidade de  $\hat{p}$  em relação a mudanças nos disparos de  $j$  é “pequena”, consideramos que  $j$  não influencia  $i$

► Isto é, tome  $\varepsilon > 0$  pequeno

► Calcule

		$w$					
		=					
$j$		0	1	1	0	0	
		=					
$i$	1	0	0	0	0	0	1

		$v$					
		=					
$j$		1	1	0	0	0	1
		=					
$i$	1	0	0	0	0	0	1

$$|\hat{p}(X(i) = 1|w) - \hat{p}(X(i) = 1|v)|$$

para “todos os pares”  $w$  e  $v$  de configurações que diferem apenas nos disparos de  $j$

# Estimador

► Se a sensibilidade de  $\hat{p}$  em relação a mudanças nos disparos de  $j$  é “pequena”, consideramos que  $j$  não influencia  $i$

► Isto é, tome  $\varepsilon > 0$  pequeno

► Calcule

		$w$					
		=					
$j$		0	1	1	0	0	
		=					
$i$		1	0	0	0	0	1

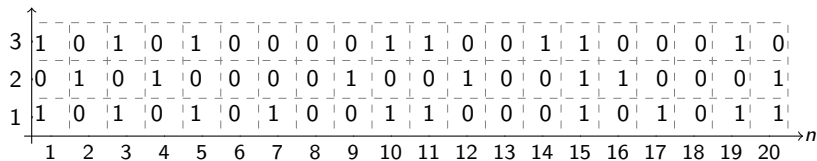
		$v$					
		=					
$j$		1	1	0	0	1	
		=					
$i$		1	0	0	0	0	1

$$|\hat{p}(X(i) = 1|w) - \hat{p}(X(i) = 1|v)|$$

para "todos os pares"  $w$  e  $v$  de configurações que diferem apenas nos disparos de  $j$

► Se **para algum par** a diferença é maior que  $\varepsilon$ , então consideramos que  $j$  influencia  $i$ .

# Exemplo




A 3x20 grid of binary values (0s and 1s) is displayed. The vertical axis on the left is labeled with 3, 2, and 1 from top to bottom. The horizontal axis at the bottom is labeled with integers from 1 to 20, with an arrow pointing to the right labeled 'n'. The grid is enclosed in a dashed border.

3	1	0	1	0	1	0	0	0	0	1	1	0	0	1	1	0	0	0	1	0
2	0	1	0	1	0	0	0	0	1	0	0	1	0	0	1	1	0	0	0	1
1	1	0	1	0	1	0	1	0	0	1	1	0	0	0	1	0	1	0	1	1
	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20




# Exemplo



$$N_{20}(1 \text{ configuração azul}) = 3$$

$$N_{20}(\text{configuração azul}) = 4$$

# Exemplo




$$N_{20}(1 \text{ configuração azul}) = 3$$

$$N_{20}(\text{configuração azul}) = 4$$

$$\hat{p}_1(1 | \text{configuração azul}) = 3/4$$


# Exemplo



$$N_{20}(1|\text{configuração verde}) = 2$$

$$N_{20}(\text{configuração verde}) = 3$$

# Exemplo




$$N_{20}(1|\text{configuração verde}) = 2$$

$$N_{20}(\text{configuração verde}) = 3$$

$$\hat{p}_1(1|\text{configuração verde}) = 2/3$$


# Exemplo



$$\hat{p}_1(1 | \text{configuração azul}) = 3/4$$

$$\hat{p}_1(1 | \text{configuração verde}) = 2/3$$

# Exemplo




$$\hat{p}_1(1 \mid \text{configuração azul}) = 3/4$$

$$\hat{p}_1(1 \mid \text{configuração verde}) = 2/3$$

$$\begin{aligned} & |\hat{p}_1(1 \mid \text{configuração azul}) - \hat{p}_1(1 \mid \text{configuração verde})| \\ &= |3/4 - 2/3| = 1/12 \gg 0 \end{aligned}$$

# Exemplo



$$\hat{p}_1(1 \mid \text{configuração azul}) = 3/4$$

$$\hat{p}_1(1 \mid \text{configuração verde}) = 2/3$$

$$\begin{aligned} & |\hat{p}_1(1 \mid \text{configuração azul}) - \hat{p}_1(1 \mid \text{configuração verde})| \\ &= |3/4 - 2/3| = 1/12 \gg 0 \end{aligned}$$

**Conclusão:** 2 influencia 1 ou  $W_{2 \rightarrow 1} \neq 0$

# Formalmente

- ▶ Uma “boa” aproximação de  $\hat{p}_i(1|w)$  depende do número de vezes que o bloco  $w$  ocorreu seguido de um disparo de  $i$
- ▶ Portanto vamos restringir o estimador aos pares  $v$  e  $w$  em que ambos blocos aparecem pelo menos  $n^{1/2+\beta}$ , com  $\beta \in (0, 1/2)$ .  
 $\Rightarrow$  Chame de  $\mathcal{T}_n$  esse conjunto

Defina a medida de sensibilidade

$$\Delta_{(i,n)}(j) = \max_{w,v \in \mathcal{T}_{(i,n)}^{w,j}} |\hat{p}_{(i,n)}(1|w) - \hat{p}_{(i,n)}(1|v)|$$



# Formalmente

- ▶ Uma “boa” aproximação de  $\hat{p}_i(1|w)$  depende do número de vezes que o bloco  $w$  ocorreu seguido de um disparo de  $i$
- ▶ Portanto vamos restringir o estimador aos pares  $v$  e  $w$  em que ambos blocos aparecem pelo menos  $n^{1/2+\beta}$ , com  $\beta \in (0, 1/2)$ .  
 $\Rightarrow$  Chame de  $\mathcal{T}_n$  esse conjunto

Defina a medida de sensibilidade

$$\Delta_{(i,n)}(j) = \max_{w,v \in \mathcal{T}_{(i,n)}^{w,j}} |\hat{p}_{(i,n)}(1|w) - \hat{p}_{(i,n)}(1|v)|$$

Assim

$$\hat{V}_n^\varepsilon = \{j \in I : \Delta_{(i,n)}(j) > \varepsilon\}$$

# Consistência

Hipótese H2:

1. Existe um  $\alpha > 0$  tal que,  $\forall u \in \mathbb{R}$ ,  $\alpha \leq \varphi(u) \leq 1 - \alpha$

## Teorema

Sob H1 e H2. Para qualquer  $i \in I$ , o seguinte vale

1. **(Superestimação)** Para qualquer  $j \in I \setminus V_{\rightarrow i}$  e qualquer  $\varepsilon > 0$

$$P(j \in \hat{V}_n^\varepsilon) \leq 4n^{3/2-\beta} \exp \left\{ -\frac{\varepsilon^2 n^{2\varepsilon}}{2} \right\}$$

2. **(Subestimação)** Para qualquer  $j \in V_{\rightarrow i}$  e qualquer  $\varepsilon > 0$   
‘suficientemente pequeno’

$$P(j \in \hat{V}_n^\varepsilon) \leq 4n^{3/2-\beta} \exp \left\{ -\frac{\varepsilon^2 n^{2\varepsilon}}{2} \right\}$$

3. Em particular, tomando  $\varepsilon = O(n^{-\beta/2})$

$$\hat{V}_n^{\varepsilon_n} = V_i \quad \text{quase certamente para } n \text{ grande}$$

# Sistemas a tempo contínuo

# Sistemas a tempo contínuo

- ▶ Evolução temporal do potencial de membrana

$$\mathbf{U}_t = (U_t(1), U_t(2), \dots, U_t(N)) \text{ com } U_t(i) \in \mathbb{R}, \forall i \in I, t \in \mathbb{R}_+$$

- ▶ Cada neurônio dispara com uma taxa que depende de  $\varphi(U_t(i))$

# Sistemas a tempo contínuo

- ▶ Evolução temporal do potencial de membrana

$$\mathbf{U}_t = (U_t(1), U_t(2), \dots, U_t(N)) \text{ com } U_t(i) \in \mathbb{R}, \forall i \in I, t \in \mathbb{R}_+$$

- ▶ Cada neurônio dispara com uma taxa que depende de  $\varphi(U_t(i))$
- ▶ Sinapses químicas: se o neurônio  $i$  dispara no instante  $t$ 
  - ▶ o seu potencial é **resetado** para 0  
 $\Rightarrow U_t(i) = 0$
  - ▶ o potencial dos demais neurônios **recebe uma quantidade**  $W_{i \rightarrow j} \in \mathbb{R}$   
 $\Rightarrow \forall j \neq i, U_t(j) = U_{t-}(j) + W_{i \rightarrow j}$  (sinapses químicas)
- ▶ Formalmente:  $\Pi^i(ds, dz), i \in I$  medidas de Poisson iid com intensidade  $d s d z$

$$U_i(t) = \sum_{j \neq i} \int_{L_t^i}^t \int_0^\infty W_{i \rightarrow j} 1_{\{z \leq \varphi(U_{s-}(j))\}} \Pi^j(ds, dz)$$

# Apenas sinapses químicas

$$\mathcal{L}f(u) = \sum_{i \in I} \varphi(u_i) [f(\Delta_i(u)) - f(u)]$$



# Apenas sinapses químicas

$$\mathcal{L}f(u) = \sum_{i \in I} \varphi(u_i) [f(\Delta_i(u)) - f(u)]$$



# Apenas sinapses químicas

$$\mathcal{L}f(u) = \sum_{i \in I} \varphi(u_i) [f(\Delta_i(u)) - f(u)]$$






# Apenas sinapses químicas

$$\mathcal{L}f(u) = \sum_{i \in I} \varphi(u_i) [f(\Delta_i(u)) - f(u)]$$




# Apenas sinapses químicas

$$\mathcal{L}f(u) = \sum_{i \in I} \varphi(u_i) [f(\Delta_i(u)) - f(u)]$$




# Apenas sinapses químicas

$$\mathcal{L}f(u) = \sum_{i \in I} \varphi(u_i) [f(\Delta_i(u)) - f(u)]$$




# Apenas sinapses químicas

$$\mathcal{L}f(u) = \sum_{i \in I} \varphi(u_i) [f(\Delta_i(u)) - f(u)]$$




# Apenas sinapses químicas

$$\mathcal{L}f(u) = \sum_{i \in I} \varphi(u_i) [f(\Delta_i(u)) - f(u)]$$




# Apenas sinapses químicas

$$\mathcal{L}f(u) = \sum_{i \in I} \varphi(u_i) [f(\Delta_i(u)) - f(u)]$$




# Apenas sinapses químicas

$$\mathcal{L}f(u) = \sum_{i \in I} \varphi(u_i) [f(\Delta_i(u)) - f(u)]$$



# Apenas sinapses químicas


$$\mathcal{L}f(u) = \sum_{i \in I} \varphi(u_i) [f(\Delta_i(u)) - f(u)]$$





# Apenas sinapses químicas

$$\mathcal{L}f(u) = \sum_{i \in I} \varphi(u_i) [f(\Delta_i(u)) - f(u)]$$



# Sistemas a tempo contínuo

- ▶ Canais de vazamento: entre disparos o potencial de cada neurônio segue um fluxo determinístico
  - ▶ Se  $L$  foi o tempo de último disparo do sistema, então

$$U_t(i) = U_L(i)e^{-\rho(t-L)}$$

# Sistemas a tempo contínuo

- ▶ Canais de vazamento: entre disparos o potencial de cada neurônio segue um fluxo determinístico
  - ▶ Se  $L$  foi o tempo de último disparo do sistema, então

$$U_t(i) = U_L(i)e^{-\rho(t-L)}$$

**Processo de Markov determinístico com partes**

# Comportamento a longo prazo do sistema

# Com canais de vazamento

Sejam  $T_k, k \geq 0$ , os tempos de disparo do sistema

## Teorema

Se  $\rho > 0$ , então

$$\sum_{k=1}^{\infty} 1_{\{T_k < \infty\}} < \infty \text{ quase certamente}$$

Isto é, o sistema tem apenas um número finito de disparos.

# Sem canais de vazamento

## Teorema

Se  $\rho = 0$ , então

$$\sum_{k=1}^{\infty} 1_{\{T_k < \infty\}} = \infty \text{ quase certamente}$$

Isto é, o sistema continua disparando indefinidamente.

# Questões em aberto

- ▶ Quando  $I$  não é infinito

# Questões em aberto

- ▶ Quando  $I$  não é infinito - **Ok!**



# Questões em aberto

- ▶ Quando  $I$  não é infinito - **Ok!**
- ▶ Quando  $V_{\rightarrow i}$  é infinito

# Questões em aberto

- ▶ Quando  $I$  não é infinito - **Ok!**
- ▶ Quando  $V_{\rightarrow i}$  é infinito
- ▶ O estimado do grafo é eficiente?

# Questões em aberto

- ▶ Quando  $I$  não é infinito - **Ok!**
- ▶ Quando  $V_{\rightarrow i}$  é infinito
- ▶ O estimado do grafo é eficiente?
- ▶ Limite hidrodinâmico

# Questões em aberto

- ▶ Quando  $I$  não é infinito - **Ok!**
- ▶ Quando  $V_{\rightarrow i}$  é infinito
- ▶ O estimado do grafo é eficiente?
- ▶ Limite hidrodinâmico
- ▶ Modelos populacionais

# Questões em aberto

- ▶ Quando  $I$  não é infinito - **Ok!**
- ▶ Quando  $V_{\rightarrow i}$  é infinito
- ▶ O estimado do grafo é eficiente?
- ▶ Limite hidrodinâmico
- ▶ Modelos populacionais
- ▶ Plasticidade

# Questões em aberto

- ▶ Quando  $I$  não é infinito - **Ok!**
- ▶ Quando  $V_{\rightarrow i}$  é infinito
- ▶ O estimado do grafo é eficiente?
- ▶ Limite hidrodinâmico
- ▶ Modelos populacionais
- ▶ Plasticidade