

# *Um breve passeio pelos Processos Estocásticos e suas aplicações*

IX Semana de Estatística – UFF  
26 de outubro de 2017

Nei Carlos dos Santos Rocha – IM-UFRJ

# Natureza dos Processos Estocásticos

- Em muitas situações estamos interessados na descrição da dinâmica de variáveis aleatórias ao longo do tempo.
- O estudo sobre as estruturas de variáveis aleatórias indexadas no tempo é o objeto principal dos Processos Estocásticos.

# O que é um Processo Estocástico?

Um processo estocástico é uma coleção infinita de variáveis aleatórias.

## Interpretação

- $X_t$  representa o estado de um sistema no tempo  $t$ .
- Se  $t \in T = \{0, 1, 2, \dots\}$ , o processo é dito a **tempo discreto**. Se  $t \in T = [0, \infty)$ , o processo é dito a **tempo contínuo**.
- $X_t \in S$ , com  $S$  denominado o **espaço de estados** do processo.

# O que é um Processo Estocástico?

Em resumo:



Um processo estocástico é uma coleção de v.a.'s  $\{X_t: t \in T\}$  parametrizada por um conjunto  $T$  denominado de **espaço parametral** para os quais as v.a.'s tomam valores num conjunto  $S$  denominado **espaço de estados**.

# Trajetória de Processos Estocásticos

Uma trajetória de um processo estocástico  $\{X_t: t \in T\}$  é uma função  $t \rightarrow X_t(\omega)$  para cada  $\omega \in \Omega$ .

- **Objetivo:**

- (a) Obter  $P(X_t \in A)$  para algum subconjunto  $A$  dos reais.
- (b) Obter  $P(X_{t_1} \in A_1, X_{t_2} \in A_2, \dots, X_{t_n} \in A_n)$  com  $A'_i$ s subconjuntos dos reais.



# Tipos de Processos Estocásticos

Existem diferentes tipos de processos estocásticos. Suas identidades são definidas a partir dos seguintes critérios:

- (a) a natureza do espaço parametral  $T$ ;
- (b) a natureza do espaço de estados  $S$ ;
- (c) a natureza das trajetórias;
- (d) a relação de dependência entre as v.a.'s que compõem o processo.

# Processos Estocásticos de Ensaios Independentes

Os fenômenos descritos por processos estocásticos independentes têm as seguintes características:

- (a)  $T = \{0, 1, 2, \dots\}$ ;
- (b)  $S$  é um subconjunto dos reais;
- (c)  $X_0, X_1, X_2, \dots$  são variáveis aleatórias independentes (ou seja, toda subcoleção finita de v.a.'s passa pelo critério de independência).

# Cadeias de Markov

Um processo  $\{X_t: t = 0, 1, 2, \dots\}$  com espaço de estados  $S$  (um subconjunto discreto dos reais) é uma **Cadeia de Markov** se, para  $x_0, x_1, x_2, \dots, x_n, x_{n+1}$  em  $S$ , tivermos

$$\begin{aligned} P(X_{n+1} = x_{n+1} | X_0 = x_0, X_1 = x_1, \dots, X_n = x_n) \\ = P(X_{n+1} = x_{n+1} | X_n = x_n) \end{aligned}$$

**(Propriedade de Markov)**

# Processos de Incrementos Independentes

Um processo  $\{X_t: t \geq 0\}$  com espaço de estados  $S$  (um subconjunto dos reais) é um **Processo de Incrementos Independentes** se, para  $0 \leq t_0 < t_1 < t_2 < \dots < t_n$ , em  $T$ , as v.a.'s

$$X_{t_0}, X_{t_1} - X_{t_0}, X_{t_2} - X_{t_1}, \dots, X_{t_n} - X_{t_{n-1}}$$

são independentes.

# Processos Estocásticos de Estacionários (Sentido Estrito)

Um processo  $\{X_t: t \geq 0\}$  com espaço de estados  $S$  (um subconjunto dos reais) é um **processo estacionário no sentido estrito** se, para quaisquer  $0 < t_0 < t_1 < \dots < t_n$  em  $T$ , e  $h > 0$  tivermos

$$(X_{t_0}, X_{t_1}, \dots, X_{t_n}) \stackrel{D}{\Leftrightarrow} (X_{t_0+h}, X_{t_1+h}, \dots, X_{t_n+h})$$

**(equivalência em distribuição)**

# Processos Estocásticos de Incrementos Estacionários

Um processo  $\{X_t: t \geq 0\}$  com espaço de estados  $S$  (um subconjunto dos reais) é um **processo de incrementos estacionários** se, para quaisquer  $0 < s < t$  em  $T$ , e  $h > 0$  tivermos

$$(X_t - X_s) \stackrel{D}{\Leftrightarrow} (X_{t+h} - X_{s+h})$$

**(equivalência em distribuição)**

# Martingais

Um processo  $\{X_t: t = 0, 1, 2, \dots\}$  com espaço de estados  $S$  (um subconjunto dos reais) é um **martingal** se, para  $x_0, x_1, x_2, \dots, x_n$  em  $S$ , tivermos

$$E(X_{n+1} | X_0 = x_0, X_1 = x_1, \dots, X_n = x_n) = x_n$$

# Processos de Lévy

Um processo  $\{X_t: t \geq 0\}$  com espaço de estados  $S$  (um subconjunto dos reais) é um **Processo de Lévy** se seus incrementos são

- (a) independentes e
- (b) estacionários.

# Processos Gaussianos

Um processo  $\{X_t: t \geq 0\}$  com espaço de estados  $S$  (um subconjunto dos reais) é um **Processo Gaussiano** se para quaisquer tempos  $0 \leq t_0 < t_1 < t_2 < \dots < t_n$ , em  $T$

$$(X_{t_0}, X_{t_1}, \dots, X_{t_n})$$

tem distribuição normal multivariada.

# Passeio pelas Cadeias de Markov


Vimos que um processo  $\{X_n: n = 0, 1, 2, \dots\}$  com  $S = \{0, 1, 2, \dots\}$  é uma **Cadeia de Markov** se, para  $x_0, x_1, x_2, \dots, x_n, x_{n+1}$  em  $S$ , tivermos

$$\begin{aligned} & P(X_{n+1} = x_{n+1} | X_0 = x_0, X_1 = x_1, \dots, X_n = x_n) \\ &= P(X_{n+1} = x_{n+1} | X_n = x_n) \end{aligned}$$

**Condição equivalente:**

$$\begin{aligned} & P(X_0 = x_0, X_1 = x_1, \dots, X_{n+1} = x_{n+1}) \\ &= P(X_0 = x_0)P(X_1 = x_1 | X_0 = x_0) \dots P(X_{n+1} = x_{n+1} | X_n = x_n) \end{aligned}$$

# Passeio pelas Cadeias de Markov





# Passeio pelas Cadeias de Markov

- A distribuição da v.a.  $X_0$  é denominada de **distribuição inicial** do processo, isto é,

$$(P(X_0 = 0), P(X_0 = 1), P(X_0 = 2), \dots) = (p_0(0), p_1(0), p_2(0) \dots)$$

- A probabilidade  $P(X_{n+1} = j | X_n = i) = p_{ij}(n, n + 1)$  é denominada **probabilidade de transição** do estado  $i$  ao estado  $j$ , do tempo  $n$  ao tempo  $n + 1$ .



# Passeio pelas Cadeias de Markov

Se

$$P(X_{n+1} = j | X_n = i) = p_{ij}(0,1) = p_{ij}(1) = p_{ij}$$

a cadeia de Markov é dita **estacionária** no tempo, pois a probabilidade de transição não depende do tempo.

## Matriz Estocástica de Probabilidades de Transição em um Passo para Cadeia de Markov Estacionária

$$P = \begin{pmatrix} & 0 & 1 & 2 & \dots \\ 0 & P_{00} & P_{01} & P_{02} & \dots \\ 1 & P_{10} & P_{11} & P_{12} & \dots \\ 2 & P_{20} & P_{21} & P_{22} & \dots \\ \vdots & \vdots & \vdots & \vdots & \vdots \end{pmatrix}$$

# Exemplo

$$S = \{0, 1, 2\}$$

$$X_0 = 1 \quad 0 \quad 1 \quad 2$$

$$P = \begin{matrix} & 0 & 1 & 2 \\ 0 & \left( \begin{array}{ccc} 0.2 & 0.3 & 0.5 \end{array} \right) \\ 1 & \left( \begin{array}{ccc} 0.5 & 0 & 0.5 \end{array} \right) \\ 2 & \left( \begin{array}{ccc} 0.4 & 0.3 & 0.3 \end{array} \right) \end{matrix}$$



# Exemplo

Suponha que desejemos calcular

$$P(X_0 = 1, X_1 = 2, X_2 = 0)$$

$$= P(X_2 = 0 | X_0 = 1, X_1 = 2)P(X_0 = 1, X_1 = 2)$$

$$= P(X_2 = 0 | X_0 = 1, X_1 = 2)P(X_1 = 2 | X_0 = 1)P(X_0 = 1)$$

$$= P(X_2 = 0 | X_1 = 2)P(X_1 = 2 | X_0 = 1)P(X_0 = 1)$$

$$= p_{2,0}(1) \cdot p_{1,2}(1) \cdot p_1(0)$$

$$= 0,4 \times 0,5 \times 1$$

$$= 0,2$$

# Propriedades da Matriz Estocástica

Seja  $P = [(p_{ij})]$  a matriz de entradas

$$p_{ij} = P(X_{n+1} = j | X_n = i) \text{ para todo } n.$$

Então as seguintes propriedades se verificam:

(a)  $p_{ij} \geq 0$  para todo  $i$  e  $j$ ;

(b)  $\sum_{j=0}^{\infty} p_{ij} = 1$

# Elementos de uma Cadeia de Markov

- Um espaço de estados  $S$ .
- Uma distribuição inicial sobre o espaço de estados  $S$ .
- Uma matriz estocástica  $P$ .

# Probabilidade de Transição $n$ passos a frente

- À probabilidade

$$P(X_{m+n} = j | X_m = i) = p_{ij}(m, m + n)$$

se denomina **probabilidade de transição** do estado  $i$  no tempo  $m$  ao estado  $j$  no tempo  $m + n$ .

- Para cadeias estacionárias, temos

$$P(X_{m+n} = j | X_m = i) = p_{ij}(m, m + n) = p_{ij}(0, n) = p_{ij}(n).$$

# Matriz Estocástica de Probabilidade de Transição $n$ passos a frente

$$P(n) = \begin{pmatrix} & 0 & 1 & 2 & \dots \\ 0 & P_{00}(n) & P_{01}(n) & P_{02}(n) & \dots \\ 1 & P_{10}(n) & P_{11}(n) & P_{12}(n) & \dots \\ 2 & P_{20}(n) & P_{21}(n) & P_{22}(n) & \dots \\ \vdots & \vdots & \vdots & \vdots & \vdots \end{pmatrix}$$

# Matriz Estocástica de Probabilidade de Transição $n$ passos a frente

## Casos Particulares

- Se  $n = 1$  então  $\mathbf{P}(1) = \mathbf{P}$ .
- Se  $n = 0$  então  $\mathbf{P}(0) := \mathbf{I}$  (matriz identidade), isto é  $p_{ij}(0) = 1$  se  $i = j$  e  $p_{ij}(0) = 0$  se  $i \neq j$ .


# Exemplo de Cadeia de Markov com Dois Estados

- Suponha  $S = \{0, 1\}$  o espaço de estados de uma cadeia de Markov.
- Suponha  $P(X_0 = 0) = p_0(0) = p$  e  $P(X_0 = 1) = p_1(0) = 1 - p = q$ .
- Suponha a matriz de transição da cadeia estacionária dada por


$$P = \begin{bmatrix} 1 - a & a \\ b & 1 - b \end{bmatrix}$$

com  $0 < a, b < 1$ .

# Exemplo de Cadeia de Markov com Dois Estados



# Exemplo de Cadeia de Markov com Dois Estados



# Exemplo de Cadeia de Markov com Dois Estados

Observe que

$$\begin{aligned}P(X_1 = 0) &= P(X_0 = 0).P(X_1 = 0|X_0 = 0)+P(X_0 = 1).P(X_1 = 0|X_0 = 1) \\&= p_0(0).p_{0,0}(1)+p_1(0).p_{1,0}(1)\end{aligned}$$

$$\begin{aligned}P(X_1 = 1) &= P(X_0 = 0).P(X_1 = 1|X_0 = 0)+P(X_0 = 1).P(X_1 = 1|X_0 = 1) \\&= p_0(0).p_{0,1}(1)+p_1(0).p_{1,1}(1)\end{aligned}$$

ou seja

$$\begin{aligned}[P(X_1 = 0) &\quad P(X_1 = 1)] = [p_0(1) \quad p_1(1)] = [p_0(0) \quad p_1(0)] \begin{bmatrix} p_{0,0} & p_{0,1} \\ p_{1,0} & p_{1,1} \end{bmatrix} \\&= [p_0(0) \quad p_1(0)].\mathbf{P}\end{aligned}$$

# Exemplo de Cadeia de Markov com Dois Estados

Da mesma forma

$$\begin{aligned}P(X_2 = 0) &= P(X_1 = 0).P(X_2 = 0|X_1 = 0)+P(X_1 = 1).P(X_2 = 0|X_1 = 1) \\&= p_0(1).p_{0,0}(1)+p_1(1).p_{1,0}(1)\end{aligned}$$

$$\begin{aligned}P(X_2 = 1) &= P(X_1 = 0).P(X_2 = 1|X_1 = 0)+P(X_1 = 1).P(X_2 = 1|X_1 = 1) \\&= p_0(1).p_{0,1}(1)+p_1(1).p_{1,1}(1)\end{aligned}$$

ou seja

$$\begin{aligned}[P(X_2 = 0) &\quad P(X_2 = 1)] = [p_0(2) &\quad p_1(2)] = [p_0(1) &\quad p_1(1)] \begin{bmatrix} p_{0,0} & p_{0,1} \\ p_{1,0} & p_{1,1} \end{bmatrix} \\&= [p_0(1) &\quad p_1(1)].\mathbf{P} \\&= [p_0(0) &\quad p_1(0)].\mathbf{P}.\mathbf{P} \\&= [p_0(0) &\quad p_1(0)].\mathbf{P}^2\end{aligned}$$

# Exemplo de Cadeia de Markov com Dois Estados

Assim, pela regularidade, temos

$$[P(X_n = 0) \quad P(X_n = 1)] = [p_0(n) \quad p_1(n)] = [p_0(0) \quad p_1(0)].\mathbf{P}^n$$

Como, no caso geral,

$$[P(X_n = 0) \quad P(X_n = 1)] = [p_0(0) \quad p_1(0)].\mathbf{P}(n),$$

concluímos que, quando a cadeia é estacionária, temos

$$\mathbf{P}(n) = [(p_{ij}(n))] = \mathbf{P}^n.$$

# Exemplo de Cadeia de Markov com Dois Estados

Pode-se mostrar por diagonalização de matrizes por meio de autovalores e autovetores que no exemplo dado temos

$$\begin{aligned}\mathbf{P}(n) &= \begin{bmatrix} p_{0,0}(n) & p_{0,1}(n) \\ p_{1,0}(n) & p_{1,1}(n) \end{bmatrix} = \begin{bmatrix} 1-a & a \\ b & 1-b \end{bmatrix}^n = \mathbf{P}^n \\ &= \frac{1}{a+b} \begin{bmatrix} b & a \\ b & a \end{bmatrix} + \frac{(1-a-b)^n}{a+b} \begin{bmatrix} a & -a \\ -b & b \end{bmatrix}\end{aligned}$$

# Exemplo de Cadeia de Markov com Dois Estados

Observe também que, como  $-1 < 1 - a - b < 1$ , temos

$$\lim_{n \rightarrow \infty} \mathbf{P}(n) = \begin{bmatrix} \frac{b}{a+b} & \frac{a}{a+b} \\ \frac{a}{a+b} & \frac{b}{a+b} \end{bmatrix}$$

ou seja, não importa onde a cadeia começa a distribuição limite de  $X_n$  existe e

$$\lim_{n \rightarrow \infty} P(X_n = 0) = \pi_0 = \frac{b}{a+b} \quad \text{e} \quad \lim_{n \rightarrow \infty} P(X_n = 1) = \pi_1 = \frac{a}{a+b}.$$

# Exemplo de Cadeia de Markov com Dois Estados

Observe também que

$$[p_0(n+1) \quad p_1(n+1)] = [p_0(n) \quad p_1(n)] \begin{bmatrix} p_{0,0} & p_{0,1} \\ p_{1,0} & p_{1,1} \end{bmatrix}$$

E que aplicando o limite quando  $n$  tende a infinito em ambos os lados, temos

$$\begin{aligned} [\pi_0 \quad \pi_1] &= [\pi_0 \quad \pi_1] \begin{bmatrix} p_{0,0} & p_{0,1} \\ p_{1,0} & p_{1,1} \end{bmatrix} \\ [\pi_0 \quad \pi_1] &= [\pi_0 \quad \pi_1] \begin{bmatrix} 1-a & a \\ b & 1-b \end{bmatrix} \end{aligned}$$

o que nos dá o sistema

$$\begin{cases} \pi_0 = (1-a)\pi_0 + b\pi_1 \\ \pi_1 = a\pi_0 + (1-b)\pi_1 \\ \pi_0 + \pi_1 = 1 \end{cases}$$

# Exemplo de Cadeia de Markov com Dois Estados

A solução do sistema coincide com os valores das colunas de

$$\lim_{n \rightarrow \infty} \mathbf{P}(n),$$

isto é,

$$\pi_0 = \frac{b}{a+b} \text{ e } \pi_1 = \frac{a}{a+b}.$$

**Problematização:** Em que circunstâncias  $\lim_{n \rightarrow \infty} \mathbf{P}(n)$  existe?

# Cadeia de Variáveis Aleatórias Independentes

Seja o processo  $\{X_n: n = 0, 1, 2, \dots\}$  com  $S = \{0, 1, 2, \dots\}$  composto por v.a.'s independentes e identicamente distribuídas, tais que

$$P(X_n = 0) = p_0, P(X_n = 1) = p_1, P(X_n = 2) = p_2, \dots$$

Então o processo é uma cadeia de Markov com probabilidade de transição, dada por,

$$P(X_{n+1} = j | X_n = i) = P(X_{n+1} = j) = p_j$$

# Cadeia de Variáveis Aleatórias Independentes

A matriz estocástica de transição é dada por

$$\mathbf{P} = \begin{bmatrix} p_0 & p_1 & p_2 & \cdots \\ p_0 & p_1 & p_2 & \cdots \\ p_0 & p_1 & p_2 & \cdots \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix}$$

# Cadeia de Variáveis Aleatórias Independentes

- Suponha agora que  $Y_n = \max\{X_1, X_2, \dots, X_n\}$ , então  $\{Y_n : n = 1, 2, \dots\}$  tem espaço de estados  $S = \{0, 1, 2, \dots\}$  é também uma cadeia de Markov e sua matriz estocástica de probabilidade de transição é dada por

$$\mathbf{P} = \begin{bmatrix} p_0 & p_1 & p_2 & \cdots \\ 0 & p_0 + p_1 & p_2 & \cdots \\ 0 & 0 & p_0 + p_1 + p_2 & \cdots \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix}$$

# Cadeia de Variáveis Aleatórias Independentes

- Suponha agora que  $Z_n = X_1 + X_2 + \dots + X_n$ , então  $\{Z_n, : n = 1, 2, \dots\}$  com  $S = \{0, 1, 2, \dots\}$  é também uma cadeia de Markov e sua matriz estocástica de probabilidade de transição é dada por

$$\mathbf{P} = \begin{bmatrix} p_0 & p_1 & p_2 & \cdots \\ 0 & p_0 & p_1 & \cdots \\ 0 & 0 & p_0 & \cdots \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix}$$

# Cadeia de Rajadas de Sucesso


Suponha agora que  $\{Y_n : n = 1, 2, \dots\}$  seja uma coleção de variáveis independentes com distribuição de Bernoulli de parâmetro  $p$  com espaço de estados  $S = \{0, 1, 2, \dots\}$ .

Seja  $X_n$  o número de sucessos consecutivos prévios até o tempo  $n$ .

| n     | 1 | 2 | 3 | 4 | 5 | 7 | ... |
|-------|---|---|---|---|---|---|-----|
| $Y_n$ | F | F | S | S | F | S | ... |
| $X_n$ | 0 | 0 | 1 | 2 | 0 | 1 | ... |

# Cadeia de Rajadas de Sucesso

$\{X_n\}$  com espaço de estados  $S = \{0, 1, 2, \dots\}$  é também uma cadeia de Markov e sua matriz estocástica de probabilidade de transição pode ser construída a partir do diagrama abaixo:



# Cadeia de Rajadas de Sucesso

Assim temos

$$p_{ij} = P(X_{n+1} = j | X_n = i) = \begin{cases} p & \text{se } j = i + 1 \\ q & \text{se } j = 0 \\ 0, \text{ caso contrário} & \end{cases}$$

$$\mathbf{P} = \begin{bmatrix} q & p & 0 & 0 & \cdots \\ q & 0 & p & 0 & \cdots \\ q & 0 & 0 & p & \\ q & 0 & 0 & 0 & \cdots \\ \vdots & \vdots & \vdots & \vdots & \vdots \end{bmatrix}$$

# Cadeia de Passeio Aleatório

Seja o processo  $\{X_n : n = 0, 1, 2, \dots\}$  com  $S = \mathbb{Z}$  (o conjunto dos números inteiros) tal que  $X_0 = 0$  e

$$p_{ij} = P(X_{n+1} = j | X_n = i) = \begin{cases} p & \text{se } j = i + 1 \\ q & \text{se } j = i - 1 \\ 0, \text{ caso contrário} & \end{cases}$$

$$\mathbf{P} = \begin{array}{c|ccccc|c} & \cdots & i-1 & i & i+1 & \cdots & \\ \vdots & \cdots & \vdots & \vdots & \vdots & \cdots & \\ i-1 & \cdots & 0 & p & 0 & \cdots & \\ i & \cdots & q & 0 & p & \cdots & \\ i+1 & \cdots & 0 & q & 0 & \cdots & \\ \vdots & \cdots & \vdots & \vdots & \vdots & \cdots & \end{array}$$

# Cadeia de Passeio Aleatório

Pode-se provar que as probabilidades de transição

$$P(X_{m+n} = j | X_m = i)$$

em  $n$  passos é dada por

$$p_{ij}(n) = \binom{n}{(n+j-i)/2} p^{(n+j-i)/2} q^{(n-j+i)/2}$$

se  $n$  e  $j - i$  são ambos pares ou ímpares e  $|j - i| \leq n$ ;

e

$$p_{ij}(n) = 0$$

em qualquer outro caso.

# Cadeia de Passeio Aleatório

Uma outra forma de construir o passeio aleatório é escrever

$$X_n = X_0 + Y_1 + Y_2 + \cdots + Y_n$$

com  $Y_i$ 's variáveis aleatórias *i.i.d.* tais que

$$P(Y_i = +1) = p \text{ e } P(Y_i = -1) = q.$$

# Cadeia do Jogador

Seja o processo  $\{X_n: n = 0, 1, 2, \dots\}$  com espaço de estados  $S = \{0, 1, \dots, N\}$  tal que  $X_0 = k \in \{1, 2, \dots, N - 1\}$  representa o capital inicial do jogador e  $N - k$  é o capital do jogador oponente. Assim, temos

- $p_{00} = 1$
- $p_{NN} = 1$
- Para  $i = 1, 2, \dots, N - 1$ ,

$$p_{ij} = \begin{cases} p & \text{se } j = i + 1 \\ q & \text{se } j = i - 1 \\ 0, \text{ caso contrário} & \end{cases}$$

O objetivo é calcular a probabilidade de ruína do jogador.

# Cadeia do Jogador

A matriz estocástica de probabilidades de transição é dada por

$$\mathbf{P} = \begin{array}{c|ccccccccc} & 0 & 1 & \cdots & k-1 & k & k+1 & \cdots & N \\ \hline 0 & 1 & 0 & \cdots & 0 & 0 & 0 & \cdots & 0 \\ 1 & q & 0 & \cdots & 0 & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \cdots & \vdots & \vdots & \vdots & \cdots & \vdots \\ \mathbf{k}-1 & 0 & 0 & \cdots & 0 & p & 0 & \cdots & 0 \\ \mathbf{k} & 0 & 0 & \cdots & q & 0 & p & \cdots & 0 \\ \mathbf{k+1} & 0 & 0 & \cdots & 0 & q & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \cdots & \vdots & \vdots & \vdots & \cdots & \vdots \\ N & 0 & 0 & \cdots & 0 & 0 & 0 & \cdots & 1 \end{array}$$

# Cadeia de Ehrenfest

Suponha  $N$  bolas numeradas de 1 a  $N$  a serem alocadas em duas urnas A e B. A partir de uma distribuição inicial das bolas nas urnas, um número de 1 a  $N$  é selecionado aleatoriamente e a bola de número selecionado é transferida da urna em que se encontra para a outra urna.

# Cadeia de Ehrenfest

Defina o processo  $\{X_n, : n = 0, 1, 2, \dots\}$  com espaço de estados  $S = \{0, 1, \dots, N\}$  tal que  $X_0 = k \in \{1, 2, \dots, N - 1\}$  representa o número de bolas inicialmente na urna A e  $X_n$  é o número de bolas na urna A após a  $n$ -ésima transferência.

# Cadeia de Ehrenfest

Então o processo  $\{X_n: n = 0, 1, 2, \dots\}$  é uma cadeia de Markov com espaço de estados  $S = \{0, 1, \dots, N\}$  e probabilidades de transição dadas por

- $p_{01} = 1$
- $p_{N,N-1} = 1$
- Para  $i = 1, 2, \dots, N - 1$ ,

$$p_{ij} = \begin{cases} \frac{(N-i)}{N}, & \text{se } j = i + 1 \\ \frac{i}{N}, & \text{se } j = i - 1 \\ 0, & \text{caso contrário} \end{cases}$$

# Cadeia de Ehrenfest

A matriz estocástica da Cadeia de Ehrenfest é dada por

$$\mathbf{P} = \begin{array}{c|cccccccccc} & 0 & 1 & 2 & \cdots & i-1 & i & i+1 & \cdots & N-1 & N \\ \hline 0 & 0 & 1 & 0 & \cdots & 0 & 0 & 0 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \cdots & \vdots & \vdots & \vdots & \cdots & \vdots & \vdots \\ i & 0 & 0 & \cdots & i/N & 0 & (N-i)/N & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \cdots & \vdots & \vdots & \vdots & \cdots & \vdots & \vdots \\ N & 0 & 0 & \cdots & 0 & 0 & 0 & \cdots & 1 & 0 \end{array}$$

# Cadeia de Ramificação

Suponha partículas que possam gerar outras partículas do mesmo tipo, como no esquema abaixo:



# Cadeia de Ramificação

Seja  $X_n$  o número de partículas da geração  $n$  e seja

$$X_0 = 1.$$

Então, se os números de descendentes de cada partícula são independentes de uma partícula a outra, o processo  $\{X_n, : n = 0, 1, 2, \dots\}$  é uma cadeia de Markov com espaço de estados  $S = \{0, 1, 2, \dots\}$ .

# Cadeia de Ramificação

Defina

$D_k^n$  : o número de descendentes da partícula  $k$  da geração  $n$ .

Então  $k = 1, 2, \dots, X_n$  ( $X_n \geq 1$ ).

Assim

$$X_{n+1} = D_1^n + D_2^n + \cdots + D_{X_n}^n$$

$$p_{ij} = P(D_1^n + D_2^n + \cdots + D_i^n = j) \text{ para } i \geq 1$$

# Cadeia de Ramificação

Essas probabilidades são estacionárias se a distribuição de  $D_k^n$  não depender de  $n$ .

**Objetivo:** Calcular a probabilidade de extinção do processo de ramificação.

# Cadeia de Fila de Espera

- Observa-se o tamanho de uma fila nos tempos discretos  $n = 0, 1, 2, \dots$
- Para cada  $n \geq 1$ , defina a v.a.  $M_n$  o número de clientes que entram em fila durante o período  $(n - 1, n]$ , tomando valores  $0, 1, 2, \dots$
- Quando há um cliente esperando na frente da fila no tempo  $n$ , este é atendido durante o período  $(n, n + 1]$ .
- A cada período somente um cliente é atendido.

# Cadeia de Fila de Espera

Seja  $X_n$  o tamanho da fila no tempo  $n$ .

Então,  $X_{n+1} = \begin{cases} M_{n+1}, & \text{se } X_n = 0 \\ M_{n+1} + X_n - 1, & \text{se } X_n \geq 1 \end{cases}$

Se  $M_1, M_2, M_3, \dots$  são independentes, então o processo  $\{X_n : n = 0, 1, 2, \dots\}$  é uma cadeia de Markov com espaço de estados  $S = \{0, 1, 2, \dots\}$ .

# Cadeia de Fila de Espera

As probabilidades de transição são dadas por

$$p_{ij}(n, n+1) = \begin{cases} P(M_{n+1} = j) & \text{se } i = 0 \\ P(M_{n+1} = j - i + 1) & \text{se } i \geq 1 \end{cases}$$

- Qual será o comportamento da fila a longo prazo?  
Crescerá sem limites?
- Qual o tempo médio de espera na fila?

# Cadeia de Fila de Espera

Se  $P(M_n = k) = p_k$ , para  $k = 0, 1, 2, \dots$  e para todo  $n$ , então a matriz estocástica é dada por:

$$\mathbf{P} = \begin{array}{c|ccccc} & 0 & 1 & 2 & 3 & \dots \\ \hline 0 & p_0 & p_1 & p_2 & p_3 & \dots \\ 1 & p_0 & p_1 & p_2 & p_3 & \dots \\ 2 & 0 & p_0 & p_1 & p_2 & \dots \\ 3 & 0 & 0 & p_0 & p_1 & \dots \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \end{array}$$

# Cadeia de Estoques

Seja  $X_n$  o número de bens em estoque nos tempos  $n = 0, 1, 2, \dots$

Em cada período  $(n - 1, n]$  uma demanda aleatória  $D_n$  de bens é requerida.

A cada tempo  $n$  é aplicada a seguinte política de abastecimento:

$$X_{n+1} = \begin{cases} A - D_{n+1} & \text{se } X_n \leq a \\ X_n - D_{n+1} & \text{se } a < X_n \leq A \end{cases}$$

com  $a$  o nível mínimo de reabastecimento e  $A$  a capacidade do estoque.

# Cadeia de Estoques

Se  $D_1, D_2, D_3, \dots$  são independentes, então o processo  $\{X_n : n = 0, 1, 2, \dots\}$  é uma cadeia de Markov com espaço de estados  $S = \{\dots, -2, -1, 0, 1, 2, \dots, A\}$ .

As probabilidades de transição são dadas por

$$p_{ij}(n, n+1) = \begin{cases} P(D_{n+1} = A - j) & \text{se } i \leq a \\ P(D_{n+1} = i - j) & \text{se } a < i \leq A \end{cases}$$

# Cadeia de Estoques

Se  $D_1, D_2, D_3, \dots$  são i.i.d. então as probabilidades de transição  
não dependem de  $n$  e são dadas por

$$p_{ij} = \begin{cases} P(D = A - j) & \text{se } i \leq a \\ P(D = i - j) & \text{se } a < i \leq A \end{cases}$$

# Cadeia de Estoques

Se  $P(D = k) = d_k$ , para  $k = 0, 1, 2, \dots$  e se, por exemplo  $a = 1$  e  $A = 3$  a matriz de transição de probabilidade é dada por

$$\mathbf{P} = \begin{array}{c|ccccc} & -1 & 0 & 1 & 2 & 3 \\ \hline 3 & \cdots & d_4 & d_3 & d_2 & d_1 & d_0 \\ 2 & \cdots & d_3 & d_2 & d_1 & d_0 & 0 \\ 1 & \cdots & d_4 & d_3 & d_2 & d_1 & d_0 \\ 0 & \cdots & d_4 & d_3 & d_2 & d_1 & d_0 \\ -1 & \cdots & d_4 & d_3 & d_2 & d_1 & d_0 \\ \vdots & \cdots & \vdots & \vdots & \vdots & \vdots & \vdots \end{array}$$


# A Equação de Chapman-Kolmogorov

Seja o processo  $\{X_n: n = 0, 1, 2, \dots\}$  uma cadeia de Markov com probabilidade de transição  $p_{ij}$ .

- **PROPOSIÇÃO:** Para qualquer par de tempos  $r$  e  $n$ , tais que  $0 \leq r < n$ , temos

$$p_{ij}(n) = \sum_k p_{ik}(r) p_{kj}(n - r)$$

# A Equação de Chapman-Kolmogorov



# A Equação de Chapman-Kolmogorov

A consequência imediata da Equação de Chapman-Kolmogorov é que

$$p_{ij}(n) = (\mathbf{P}^n)_{ij}$$

ou seja  $p_{ij}(n)$  é a entrada  $(i, j)$  da matriz  $\mathbf{P}^n$ .

# Comunicação

Seja o processo  $\{X_n: n = 0, 1, 2, \dots\}$  uma cadeia de Markov com probabilidade de transição  $p_{ij}$ .

**Definição:** Sejam  $i$  e  $j$  dois estados da cadeia de Markov.

(a)  $j$  é dito **acessível** por  $i$  ( $i \rightarrow j$ ) se existe  $n \geq 0$  tal que

$$p_{ij}(n) > 0.$$

(b)  $i$  e  $j$  são ditos **comunicáveis** ( $i \leftrightarrow j$ ) se  $i \rightarrow j$  e  $j \rightarrow i$ .

# Comunicação

**PROPOSIÇÃO:** A comunicação é uma relação de equivalência, ou seja, é

(a) Reflexiva :  $i \leftrightarrow i$

(b) Simétrica: se  $i \leftrightarrow j$  então  $j \leftrightarrow i$

(c) Transitiva: se  $i \leftrightarrow j$  e  $j \leftrightarrow k$  então  $i \leftrightarrow k$

# Comunicação

A comunicação induz uma partição do espaço de estados em classes comunicáveis.


Seja  $C(i)$  a classe de comunicação do estado  $i$ .

**Definição:** Uma cadeia de Markov é dita **irreduzível** se todos os seus estados se comunicam entre si.

# Comunicação

Exemplo

$$P = \begin{bmatrix} 0 & 1 & 2 & 3 \\ 0 & 1 & 0 & 0 & 0 \\ 1 & \frac{1}{2} & 0 & \frac{1}{2} & 0 \\ 2 & 0 & \frac{1}{2} & \frac{1}{2} & 0 \\ 3 & \frac{1}{2} & 0 & \frac{1}{2} & 0 \end{bmatrix}$$



# Período - Definição

Seja  $i$  um estado de uma cadeia de Markov  $\{X_n: n = 0, 1, 2, \dots\}$


**Definição:** O período de  $i$  é o inteiro definido como

$$d(i) = \text{mdc}\{n \geq 1: p_{ii}(n) > 0\}.$$

- Quando  $p_{ii}(n) = 0$  para  $n \geq 1$ , define-se  $d(i) = 0$ .
- Se  $d(i) = 1$ , diz-se que  $i$  é **aperiódico**.
- Se  $d(i) = k$ , diz-se que  $i$  é **periódico de período  $k$** .

# Período - Definição

Seja a Cadeia de Markov do diagrama abaixo:



$$d(0) = \text{mdc}\{1, 2, \dots\} = 1$$

$$d(1) = \text{mdc}\{2, 4, \dots\} = 2$$

$$d(2) = \text{mdc}\{2, 4, \dots\} = 2$$

$$d(3) = \text{mdc}\emptyset = 0$$

# Período - Propriedades

**PROPOSIÇÃO:** Se  $i \leftrightarrow j$ , então  $d(i) = d(j)$ .

**PROPOSIÇÃO:** Para cada estado  $i$ , existe  $n_0 \in \mathbb{N}$  tal que, para todo  $n \geq n_0$ ,  $p_{ii}(nd(i)) > 0$ .

**PROPOSIÇÃO:** Para  $i \neq j$  tais que  $p_{ij}(m) > 0$ , para algum  $m \geq 1$ , existe  $n_0 \in \mathbb{N}$  tal que, para todo  $n \geq n_0$ ,  $p_{ij}(m + nd(i)) > 0$ .

# Probabilidade de Primeiras Visitas

Sejam  $i$  e  $j$  dois estados de uma cadeia de Markov.


**Definição:** Para todo  $n \geq 1$  a probabilidade de primeira visita ao estado  $j$ ,  $n$  passos após a cadeia iniciar no estado  $i$  é dada por

$$f_{ij}(n) = P(X_n = j, X_{n-1} \neq j, \dots, X_1 \neq j | X_0 = i)$$

Define-se também  $f_{ij}(0) = 0$  e  $f_{ii}(0) = 0$ .

# Probabilidade de Primeiras Visitas

Sejam uma cadeia de Markov de dois estados, segundo o diagrama abaixo



Então

$$f_{01}(n) = (1 - a)^{n-1} a, \text{ para } n \geq 1$$

$$f_{00}(n) = a(1 - b)^{n-2} b, \text{ para } n \geq 2$$

# Probabilidade de Primeiras Visitas

**PROPOSIÇÃO:** Para  $n \geq 1$ ,

$$p_{ij}(n) = \sum_{k=1}^n f_{ij}(k) p_{jj}(n-k)$$

- A probabilidade de uma eventual visita ao estado  $j$  começando a cadeia no estado  $i$  é dada por

$$f_{ij} = \sum_{n=1}^{\infty} f_{ij}(n)$$

# Recorrência e Transitoriedade - Definição

Seja  $i$  um estado de uma cadeia de Markov  $\{X_n: n = 0, 1, 2, \dots\}$

**Definição:** Diz-se que o estado  $i$  é

(a) **recorrente** se

$$P(X_n = i, \text{ para algum } n \geq 1 | X_0 = i) = 1;$$

(b) **transiente** se

$$P(X_n = i, \text{ para algum } n \geq 1 | X_0 = i) < 1.$$

# Recorrência e Transitoriedade - Critérios

Seja  $f_{ii} = \sum_{n=1}^{\infty} f_{ii}(n)$ , então pode-se mostrar:

**PROPOSIÇÃO:** O estado  $i$  é

(a) **recorrente** se e somente se

$$f_{ii} = 1;$$

(b) **transiente** se e somente se

$$f_{ii} < 1.$$

# Recorrência e Transitoriedade - Critérios

**PROPOSIÇÃO:** O estado  $i$  é

(a) **recorrente** se e somente se

$$\sum_{n=1}^{\infty} p_{ii}(n) = \infty;$$

(b) **transiente** se e somente se

$$\sum_{n=1}^{\infty} p_{ii}(n) < \infty.$$

# Recorrência e Transitoriedade - Critérios

Pode-se mostrar que recorrência e transiência são propriedades de classes.

Assim se dois estados  $i$  e  $j$  estão na mesma classe ( $i \leftrightarrow j$ ), então

- (a) se  $i$  é recorrente,  $j$  também o será;
- (b) se  $i$  é transitente,  $j$  também o será.

# Recorrência e Transiência - Critérios


**PROPOSIÇÃO:** Seja qualquer estado inicial  $i$  e seja  $j$  um estado **transiente**. Então

- (a)  $\sum_{n=1}^{\infty} p_{ij}(n) < \infty$ .
- (b)  $\lim_{n \rightarrow \infty} p_{ij}(n) = 0$ .

**COROLÁRIO:** Toda cadeia finita e irredutível é recorrente.

# Recorrência e Transiência - Definição

Seja uma cadeia de Markov de dois estados segundo o diagrama abaixo, com  $0 < a, b < 1$ .



Então, 0 é um estado recorrente?

$$f_{00}(1) = 1 - a \text{ e}$$
$$f_{00}(n) = a(1 - b)^{n-2}b, \text{ para } n \geq 2$$

# Recorrência e Transiência


Assim

$$\begin{aligned}f_{00} &= \sum_{n=1}^{\infty} f_{00}(n) = (1 - a) + \sum_{n=2}^{\infty} a(1 - b)^{n-2}b \\&= (1 - a) + ab \sum_{n=2}^{\infty} (1 - b)^{n-2} = (1 - a) + ab \times \frac{1}{b} \\&= 1\end{aligned}$$

Ou seja, o estado 0 é **recorrente**. Analogamente, se mostra que o estado 1 é também **recorrente**, pois 0 e 1 pertencem à mesma classe.

# Recorrência e Transiência

Seja a Cadeia de Rajadas de Sucessos, dada pelo diagrama abaixo com  $0 < p < 1$  e  $p + q = 1$ .



Pergunta-se: 0 é um estado recorrente?

$$f_{00}(1) = q \text{ e}$$

$$f_{00}(n) = p^{n-1}q, \text{ para } n \geq 2$$

# Recorrência e Transiência


Assim

$$\begin{aligned}f_{00} &= \sum_{n=1}^{\infty} f_{00}(n) = q + \sum_{n=2}^{\infty} p^{n-1}q \\&= q + q \sum_{n=2}^{\infty} p^{n-1} = q + q \times \frac{p}{1-p} \\&= p + q \\&= 1\end{aligned}$$

Ou seja, o estado 0 é **recorrente**. Analogamente, se mostra que todos os outros estados são também **recorrentes**, pois a cadeia é irredutível.


# Recorrência e Transiência

Seja a cadeia dada pelo diagrama abaixo



Como  $p_{00}(n) = 1$  e  $\sum_{n=1}^{\infty} p_{00}(n) = \sum_{n=1}^{\infty} 1 = \infty$ , segue-se que 0 é **recorrente**.


# Recorrência e Transiência



Como  $f_{11} = \sum_{n=1}^{\infty} f_{11}(n) = \sum_{n=2}^{\infty} \frac{1}{2} \left(\frac{1}{2}\right)^{n-2} \frac{1}{2} = \frac{1}{2} < 1$  ,

segue-se que 1 é **transiente**.


# Recorrência e Transiência



Como os estados 1 e 2 pertencem à mesma classe e como 1 é **transiente**, segue-se que 2 é também **transiente**, o que se comprova por

$$f_{22} = \sum_{n=1}^{\infty} f_{22}(n) = f_{22}(1) + f_{22}(2) = \frac{1}{2} + \frac{1}{2} \times \frac{1}{2} = \frac{3}{4} < 1$$

# Recorrência e Transiência



Como  $\sum_{n=1}^{\infty} p_{33}(n) = \sum_{n=1}^{\infty} 0 < \infty$ , temos que o estado 3 é **transiente**.

# Tempo Médio de Recorrência

Seja  $j$  um estado **recorrente**.

**Problematização:** Quanto tempo em média leva a cadeia para regressar ao estado  $j$ ?

**Definição:** O tempo médio de recorrência de um estado recorrente  $j$  é dado por

$$\mu_j = \sum_{n=1}^{\infty} n f_{jj}(n)$$

# Tempo Médio de Recorrência


Mais geralmente, temos a seguinte definição

**Definição:** O tempo médio de recorrência de um estado recorrente  $j$  a partir do estado  $i$  é dado por

$$\mu_{ij} = \sum_{n=1}^{\infty} n f_{ij}(n)$$

# Tempo Médio de Recorrência

Seja uma cadeia de Markov de dois estados segundo o diagrama abaixo, com  $0 < a, b < 1$ .



Então, qual o tempo médio de recorrência do estado 0?

$$f_{00}(1) = 1 - a \text{ e}$$

$$f_{00}(n) = a(1 - b)^{n-2}b, \text{ para } n \geq 2$$

# Tempo Médio de Recorrênci

$$\begin{aligned}\mu_0 &= \sum_{n=1}^{\infty} n f_{00}(n) = (1 - a) + \sum_{n=2}^{\infty} na(1 - b)^{n-2}b \\ &= (1 - a) + ab \sum_{n=2}^{\infty} n(1 - b)^{n-2} \\ &= (1 - a) + ab(b + 1)/b^2\end{aligned}$$

$$\mu_0 = \frac{a + b}{b}$$

# Tempo Médio de Recorrência

De maneira análoga se pode mostrar que

$$\mu_1 = \frac{a + b}{a}$$

Observe que

$$\frac{1}{\mu_0} + \frac{1}{\mu_1} = 1.$$

**Exercício:** Calcule você mesmo(a)  $\mu_{01}$  e  $\mu_{10}$ .

# Classes Fechadas


Seja o processo  $\{X_n: n = 0, 1, 2, \dots\}$  uma cadeia de Markov com espaço de estados  $S$ .

**Definição:** Uma coleção não vazia de estados  $C$  é **fechada** se nenhum estado fora de  $C$  é acessível a partir de algum estado dentro de  $C$ .

- Se  $i$  é um estado absorvente ( $p_{ii} = 1$ ) então  $C = \{i\}$ .
- $C = \{estados\;recorrentes\}$

# Classes Fechadas

- Para a cadeia abaixo, temos as seguintes classes fechadas:



$$C_1 = \{1, 2\}, C_2 = \{0, 1, 2\}, C_3 = \{1, 2, 3\}, C_4 = \{0, 1, 2, 3\}$$

# Classes Fechadas

Pode-se provar o seguinte resultado para classes fechadas e irreduutíveis:

**PROPOSIÇÃO:** Toda classe  $C$  fechada e irreduutível é uma classe de comunicação.

# Número de Visitas

Sejam  $i$  e  $j$  dois estados de uma cadeia de Markov  $\{X_n: n = 0, 1, 2, \dots\}$  com espaço de estados  $S$ . Suponha  $X_0 = i$ .

Para  $n = 1, 2, \dots$  defina a v.a.

$$N_{ij}(n) = \sum_{k=1}^n \mathbf{1}_{(X_k=j)}$$

Então,

- $0 \leq N_{ij}(1) \leq N_{ij}(2) \leq \dots$
- $\lim_{n \rightarrow \infty} N_{ij}(n) = N_{ij} = \sum_{k=1}^{\infty} \mathbf{1}_{(X_k=j)}$  quase certamente.

# Número de Visitas

Pode-se provar os seguintes resultados:

**PROPOSIÇÃO:**

$$(a) \ P(N_{ij} \geq k) = \begin{cases} 1, & \text{se } k = 0 \\ f_{ij}(f_{jj})^{k-1}, & \text{se } k \geq 1 \end{cases}$$

$$(b) \ P(N_{ij} = k) = \begin{cases} 1 - f_{ij}, & \text{se } k = 0 \\ f_{ij}(f_{jj})^{k-1}(1 - f_{jj}), & \text{se } k \geq 1 \end{cases}$$

# Número de Visitas

$$(c) \ E(N_{ij}) = \begin{cases} 0, & \text{se } f_{ij} = 0 \\ \frac{f_{ij}}{1-f_{jj}}, & \text{se } 0 \leq f_{ij} < 1 \\ \infty, & \text{se } f_{ij} \neq 0 \text{ e } f_{jj} = 1 \end{cases}$$

$$(d) \ P(N_{ij} = \infty) = \begin{cases} 0, & \text{se } j \text{ é transiente} \\ f_{ij}, & \text{se } j \text{ é recorrente} \end{cases}$$

$$(e) \ P(N_{ij} < \infty) = \begin{cases} 1, & \text{se } j \text{ é transiente} \\ 1 - f_{ij}, & \text{se } j \text{ é recorrente} \end{cases}$$


# Propriedade Forte de Markov

Seja o processo  $\{X_n: n = 0, 1, 2, \dots\}$  uma Cadeia de Markov com espaço de estados  $S$ .

**Definição:** Uma v.a.  $\tau: \Omega \rightarrow \{0, 1, 2, \dots, \infty\}$  é um tempo de parada (**stopping time**) com respeito a  $\{X_n\}$  se o evento  $\{\tau = n\}$  depende unicamente de  $X_0, X_1, \dots, X_n$ .

# Propriedade Forte de Markov

Seja uma cadeia de Markov de dois estados segundo o diagrama abaixo, com  $0 < a, b < 1$ .



Suponha  $X_0 = 0$  e defina  $\tau = \min\{n \geq 1: X_n = 1\}$ . Então  $\tau$  é um tempo de parada, pois, para  $n = 1, 2, \dots$ ,

$$\{\tau = n\} = \{X_1 = 0, X_2 = 0, \dots, X_{n-1} = 0, X_n = 1\}.$$

# Propriedade Forte de Markov

**PROPOSIÇÃO:** Seja o processo  $\{X_n: n = 0, 1, 2, \dots\}$  uma cadeia de Markov com espaço de estados  $S$  e seja  $\tau$  um tempo de parada finito.

Então  $\{X_{\tau+n}: n = 0, 1, 2, \dots\}$  é também uma cadeia de Markov.  
Assim

$$\begin{aligned} P(X_{\tau+n+1} = j | X_0 = x_0, X_1 = x_1, \dots, X_{\tau+n-1} = x_{n-1}, X_{\tau+n} = i) \\ = P(X_{\tau+n+1} = j | X_{\tau+n} = i) \end{aligned}$$

**(Propriedade Forte de Markov)**

# Teorema Ergódico para Cadeias de Markov

Sejam  $i$  e  $j$  dois estados de uma cadeia de Markov  $\{X_n: n = 0, 1, 2, \dots\}$  com espaço de estados  $S$ . Suponha  $X_0 = i$  e seja

$$N_{ij}(n) = \sum_{k=1}^n \mathbf{1}_{(X_k=j)}$$

**Teorema Ergódico:** Se a cadeia de Markov é irredutível e recorrente, então

$$\lim_{n \rightarrow \infty} \frac{N_{ij}(n)}{n} = \frac{1}{\mu_j}$$

quase certamente, com  $\mu_j$  o tempo médio de recorrência ao estado  $j$ .

# Teorema Ergódico para Cadeias de Markov

**Interpretação:** Para cadeias irreductíveis e recorrentes, o número

$$\pi_j = \frac{1}{\mu_j}$$

é a frequência relativa do número de visitas ao estado  $j$  a longo prazo.

# Teorema Ergódico para Cadeias de Markov


**Corolário do Teorema Ergódico:** Se a cadeia de Markov é irredutível e recorrente, então

$$\lim_{n \rightarrow \infty} \frac{\sum_{k=1}^n p_{ij}(k)}{n} = \frac{1}{\mu_j}$$

quase certamente, com  $\mu_j$  o tempo médio de recorrência ao estado  $j$ .

# Teorema Ergódico para Cadeias de Markov

Seja uma cadeia de Markov de dois estados segundo o diagrama abaixo, com  $0 < a, b < 1$ .



Vimos que  $\mu_0 = \frac{a+b}{b}$  e  $\mu_1 = \frac{a+b}{a}$ . Assim

$$\pi_0 = \frac{1}{\mu_0} = \frac{b}{a+b} \text{ e } \pi_1 = \frac{1}{\mu_1} = \frac{a}{a+b},$$

valores esses encontrados antes na distribuição limite.

# Teorema Ergódico para Cadeias de Markov

Se, por exemplo,  $a = 0,2$  e  $b = 0,3$ , temos

$$\pi_0 = \frac{0,3}{0,5} = 0,6$$

$$\text{e } \pi_1 = \frac{0,2}{0,5} = 0,4,$$

ou seja em 60% do tempo a cadeia se encontra no estado 0 e em 40% do tempo a cadeia se encontra no estado 1.

# Recorrência Positiva e Nula

Seja  $i$  um estado **recorrente** com tempo médio de recorrência dado por

$$\mu_i = \sum_{n=1}^{\infty} n f_{ii}(n)$$

**Definição:** Diz-se que o estado  $i$  é recorrente

(a) **positivo** se

$$\mu_i < \infty;$$

(b) **nulo** se

$$\mu_i = \infty.$$

# Recorrência Positiva e Nula

**PROPOSIÇÃO:** Recorrência positiva e recorrência nula são propriedades de classe, isto é, se  $i \leftrightarrow j$ , então


- (a) se  $i$  é recorrente positivo, então  $j$  é recorrente positivo;
- (b) se  $i$  é recorrente nulo, então  $j$  é recorrente nulo.

Há portanto três classes possíveis: classe transitória, classe recorrente positiva e classe recorrente nula.

**PROPOSIÇÃO:** Não existem estados recorrentes nulos em cadeias de Markov finitas.

# Recorrência Positiva e Nula

Seja a Cadeia de Rajadas de Sucessos, dada pelo diagrama abaixo com  $0 < p < 1$  e  $p + q = 1$ .



**Pergunta-se:** 0 é um estado recorrente positivo, isto é,

$$\mu_0 = \sum_{n=1}^{\infty} n f_{00}(n) < \infty?$$

# Recorrência Positiva e Nula

Vimos que  $f_{00}(n) = p^{n-1}q$ , para  $n \geq 1$ .

Assim

$$\begin{aligned}\mu_0 &= \sum_{n=1}^{\infty} n f_{00}(n) = \sum_{n=1}^{\infty} np^{n-1}q \\ &= q \sum_{n=1}^{\infty} np^{n-1} = q \frac{1}{(1-p)^2} \\ &= \frac{1}{q} < \infty\end{aligned}$$

Logo, 0 bem como todos os demais estados são recorrentes positivos (pois a cadeia é irredutível).

# O que é uma distribuição estacionária?

Seja o processo  $\{X_n : n = 0, 1, 2, \dots\}$  uma cadeia de Markov com espaço de estados  $S = \{0, 1, 2, \dots\}$  com matriz de transição  $P$  e com **distribuição inicial**

$$\mathbf{p}(0) = (p_0(0), p_1(0), p_2(0) \dots).$$

Se  $\mathbf{p}(1) = (p_0(1), p_1(1), p_2(1) \dots)$  é a distribuição de  $X_1$ , então temos

$$\mathbf{p}(1) = \mathbf{p}(0)P \text{ e}$$

$$\mathbf{p}(n + 1) = \mathbf{p}(n)P$$

# O que é uma distribuição estacionária?

Assim, resolvendo a recorrência, chegamos a

$$\mathbf{p}(n) = \mathbf{p}(0)\mathbf{P}^n$$

**Problematização:**  $\mathbf{p}(n)$  é convergente? Em geral a resposta é negativa. Veremos as condições para que isso aconteça.

# O que é uma distribuição estacionária?

**Definição:** Uma distribuição de probabilidade

$$\boldsymbol{\pi} = (\pi_0, \pi_1, \pi_2, \dots)$$


é **estacionária** ou **invariante** para a cadeia com matriz de transição  $P$  se  $\boldsymbol{\pi} = \boldsymbol{\pi}P$ .

Há três casos a considerar para a cadeia:

- Existe uma única distribuição estacionária.
- Não existe distribuição estacionária.
- Há uma infinidade de distribuições estacionárias.

# Exemplo de Distribuição Estacionária Única

Seja a cadeia de Markov abaixo:



# Exemplo de Distribuição Estacionária Única

Defina  $\boldsymbol{\pi} = (\pi_0, \pi_1, \pi_2)$

Então o sistema  $\boldsymbol{\pi} = \boldsymbol{\pi}P$  é dado por

$$(\pi_0, \pi_1, \pi_2) = (\pi_0, \pi_1, \pi_2) \begin{pmatrix} 1/2 & 1/2 & 0 \\ 0 & 1/2 & 1/2 \\ 1/2 & 0 & 1/2 \end{pmatrix}$$

$$\begin{cases} \pi_0 = (\pi_0 + \pi_2)/2 \\ \pi_1 = (\pi_0 + \pi_1)/2 \\ \pi_2 = (\pi_1 + \pi_2)/2 \\ \pi_0 + \pi_1 + \pi_2 = 1 \end{cases}$$

cuja solução é  $\boldsymbol{\pi} = (\pi_0, \pi_1, \pi_2) = \left(\frac{1}{3}, \frac{1}{3}, \frac{1}{3}\right)$ .

## Distribuições Estacionárias – Exemplo de Não-Existência

Seja o processo  $\{X_n : n = 0, 1, 2, \dots\}$  com  $S = \mathbb{Z}$  tal que  $X_0 = 0$  e

$$p_{ij} = P(X_{n+1} = j | X_n = i) = \begin{cases} 1/2 & \text{se } j = i + 1 \\ 1/2 & \text{se } j = i - 1 \\ 0, \text{ caso contrário} & \end{cases}$$

$$\mathbf{P} = \begin{array}{ccccc} & i-1 & i & i+1 & \cdots \\ \vdots & \cdots & \vdots & \vdots & \cdots \\ i-1 & \cdots & 0 & 1/2 & 0 & \cdots \\ i & \cdots & 1/2 & 0 & 1/2 & \cdots \\ i+1 & \cdots & 0 & 1/2 & 0 & \cdots \\ \vdots & \cdots & \vdots & \vdots & \vdots & \cdots \end{array}$$

## Distribuições Estacionárias – Exemplo de Não-Existência

$\pi = (\dots, \pi_{-1}, \pi_0, \pi_1, \dots)$  é uma distribuição estacionária se

$$\pi = \pi P$$

Assim

$$\pi_i = \frac{1}{2}\pi_{i-1} + \frac{1}{2}\pi_{i+1} \text{ para todo } i \in \mathbb{Z}, \text{ ou seja,}$$

$$\pi_{i+1} - \pi_i = \pi_i - \pi_{i-1} \text{ para todo } i \in \mathbb{Z}$$

$$\pi_1 - \pi_0 = \pi_1 - \pi_0$$

$$\pi_2 - \pi_1 = \pi_1 - \pi_0$$

$$\pi_3 - \pi_2 = \pi_1 - \pi_0$$

$$\pi_4 - \pi_3 = \pi_1 - \pi_0$$

⋮

$$\pi_n - \pi_{n-1} = \pi_1 - \pi_0$$

## Distribuições Estacionárias – Exemplo de Não-Existência

Somando ambos os lados, temos

$$\pi_n - \pi_0 = n(\pi_1 - \pi_0) \text{ para todo } n$$


Para  $n$  tendendo ao infinito a igualdade só poderá ser satisfeita se  $\pi_1 - \pi_0 = 0$ , mas isso implica que

$$\pi_i - \pi_{i-1} = 0$$

para todo  $i \in \mathbb{Z}$ . Assim  $\pi_i = p$  constante. Mas isso é impossível pois a cadeia tem infinitos estados. Logo, a cadeia não admite nenhuma distribuição estacionária.

## Distribuições Estacionárias – Exemplos de Existência Múltipla

- Seja a cadeia de Markov dada abaixo:



## Distribuições Estacionárias – Exemplos de Existência Múltipla

Defina  $\boldsymbol{\pi} = (\pi_0, \pi_1, \pi_2)$ . Então o sistema  $\boldsymbol{\pi} = \boldsymbol{\pi}P$  é dado por

$$(\pi_0, \pi_1, \pi_2) = (\pi_0, \pi_1, \pi_2) \begin{pmatrix} 1 & 0 & 0 \\ 1/3 & 1/3 & 1/3 \\ 0 & 0 & 1 \end{pmatrix}$$
$$\left\{ \begin{array}{l} \pi_0 = \pi_0 + \pi_1/3 \\ \pi_1 = \pi_1/3 \\ \pi_2 = \pi_1/3 + \pi_2 \\ \pi_0 + \pi_1 + \pi_2 = 1 \end{array} \right.$$

Temos que  $\pi_1 = 0$  e o sistema se reduz a

## Distribuições Estacionárias – Exemplos de Existência Múltipla

$$\left\{ \begin{array}{l} \pi_0 = \pi_0 \\ \pi_1 = 0 \\ \pi_2 = \pi_2 \\ \pi_0 + \pi_1 + \pi_2 = \pi_0 + \pi_2 = 1 \end{array} \right.$$

Assim, temos infinitas soluções, tomando  $\pi_0 = \alpha$  e  $\pi_2 = 1 - \alpha$  com  $0 \leq \alpha \leq 1$ , do tipo

$$\boldsymbol{\pi} = (\pi_0, \pi_1, \pi_2) = (\alpha, 0, 1 - \alpha).$$

Há portanto uma infinidade de distribuições estacionárias.

## Distribuições Estacionárias – Exemplos de Existência Múltipla

**Exercício:** Mostre que a Cadeia do Jogador admite também uma infinidade de distribuições estacionárias.

# Distribuições Estacionárias – Dois Resultados

**PROPOSIÇÃO:** Sejam  $\pi$  e  $\pi'$  duas distribuições estacionárias distintas para uma cadeia com matriz  $P$ .

Para todo  $0 \leq \alpha \leq 1$ ,

$$\alpha\pi + (1 - \alpha)\pi'$$

é também uma distribuição estacionária.

# Distribuições Estacionárias – Dois Resultados


**PROPOSIÇÃO:** Sejam  $\pi = (\pi_j)_{j \in S}$  uma distribuição estacionária para uma cadeia de Markov com matriz  $P$ .

Se  $j$  é um estado transiente ou recorrente nulo, então

$$\pi_j = 0.$$

# Distribuições Estacionárias – Dois Resultados

Seja a cadeia abaixo



# Distribuições Estacionárias – Dois Resultados

Vamos mostrar que para o estado 2 transiente teremos  $\pi_2 = 0$ .

Defina  $\boldsymbol{\pi} = (\pi_0, \pi_1, \pi_2)$ .

Então o sistema  $\boldsymbol{\pi} = \boldsymbol{\pi}P$  é dado por

$$(\pi_0, \pi_1, \pi_2) = (\pi_0, \pi_1, \pi_2) \begin{pmatrix} 1-a & a & 0 \\ b & 1-b & 0 \\ 0 & 1/2 & 1/2 \end{pmatrix}$$

$$\begin{cases} \pi_0 = (1-a)\pi_0 + b\pi_1 \\ \pi_1 = a\pi_0 + (1-b)\pi_1 + \pi_2/2 \\ \pi_2 = \pi_2/2 \\ \pi_0 + \pi_1 + \pi_2 = 1 \end{cases}$$

cuja solução é  $\boldsymbol{\pi} = (\pi_0, \pi_1, \pi_2) = \left( \frac{b}{a+b}, \frac{a}{a+b}, 0 \right)$ .

# Distribuições Estacionárias – Existência e Unicidade

Quando uma cadeia de Markov admite uma única distribuição estacionária?

**PROPOSIÇÃO:** Toda cadeia de Markov irredutível e recorrente positiva admite uma única distribuição estacionária  $\pi = (\pi_j)_{j \in S}$  dada por

$$\pi_j = \frac{1}{\mu_j} > 0.$$

# O que é uma Distribuição Limite?


Seja o processo  $\{X_n: n = 0, 1, 2, \dots\}$  uma cadeia de Markov com matriz de probabilidade de transição  $P[(p_{ij})]$ .

**Definição:** A distribuição limite de  $\{X_n\}$  é o vetor  $\pi^\infty = (\pi_0^\infty, \pi_1^\infty, \pi_2^\infty, \dots)$  onde

$$\pi_j^\infty = \lim_{n \rightarrow \infty} p_{ij}(n)$$

se o limite existe para todo estado  $j$  e não depende do estado  $i$ .

# Distribuição Limite da Cadeia de Markov com Dois Estados



# Distribuição Limite da Cadeia de Markov com Dois Estados

Vimos que

$$\begin{aligned} \mathbf{P}(n) &= \begin{bmatrix} p_{0,0}(n) & p_{0,1}(n) \\ p_{1,0}(n) & p_{1,1}(n) \end{bmatrix} = \begin{bmatrix} 1-a & a \\ b & 1-b \end{bmatrix}^n = \mathbf{P}^n \\ &= \frac{1}{a+b} \begin{bmatrix} b & a \\ b & a \end{bmatrix} + \frac{(1-a-b)^n}{a+b} \begin{bmatrix} a & -a \\ -b & b \end{bmatrix} \end{aligned}$$

# Distribuição Limite da Cadeia de Markov com Dois Estados

E que, como  $-1 < 1 - a - b < 1$ , temos


$$\lim_{n \rightarrow \infty} P(n) = \begin{bmatrix} \frac{b}{a+b} & \frac{a}{a+b} \\ \frac{b}{a+b} & \frac{a}{a+b} \end{bmatrix}$$

ou seja, não importa onde a cadeia começa, a distribuição limite existe e é dada por

$$\pi_0^\infty = \lim_{n \rightarrow \infty} p_{i0}(n) = \frac{b}{a+b} \text{ e } \pi_1^\infty = \lim_{n \rightarrow \infty} p_{i1}(n) = \frac{a}{a+b}.$$

# Distribuição Limite que não é Distribuição de Probabilidade

Seja a cadeia de Markov abaixo.



Mostraremos que a distribuição limite existe, mas não é uma distribuição de probabilidade.

# Distribuição Limite que não é Distribuição de Probabilidade

A matriz de transição é dada por

$$\mathbf{P} = \begin{array}{c|cccccc} & 0 & 1 & 2 & 3 & \dots \\ \hline 0 & 1/2 & 1/2 & 0 & 0 & \dots \\ 1 & 0 & 1/2 & 1/2 & 0 & \dots \\ 2 & 0 & 0 & 1/2 & 1/2 & \dots \\ 3 & 0 & 0 & 0 & 1/2 & \dots \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \end{array}$$

# Distribuição Limite que não é Distribuição de Probabilidade

A matriz  $P^2$  é dada por

$$\mathbf{P}^2 = \begin{array}{c|ccccccccc} & 0 & 1 & 2 & 3 & \cdots \\ \hline 0 & (1/2)^2 & 2(1/2)^2 & (1/2)^2 & 0 & \cdots \\ 1 & 0 & (1/2)^2 & 2(1/2)^2 & (1/2)^2 & \cdots \\ 2 & 0 & 0 & (1/2)^2 & 2(1/2)^2 & \cdots \\ 3 & 0 & 0 & 0 & (1/2)^2 & \cdots \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \end{array}$$

# Distribuição Limite que não é Distribuição de Probabilidade


A matriz  $\mathbf{P}^2$  é dada por

$$\mathbf{P}^2 = \begin{array}{c|ccccc} & 0 & 1 & 2 & 3 & \dots \\ \hline 0 & (1/2)^2 & 2(1/2)^2 & (1/2)^2 & 0 & \dots \\ 1 & 0 & (1/2)^2 & 2(1/2)^2 & (1/2)^2 & \dots \\ 2 & 0 & 0 & (1/2)^2 & 2(1/2)^2 & \dots \\ 3 & 0 & 0 & 0 & (1/2)^2 & \dots \\ \vdots & \vdots & \vdots & \vdots & \vdots & \end{array}$$

e se pode mostrar que para quaisquer  $i$  e  $j$ ,  $\lim_{n \rightarrow \infty} p_{ij}(n) = 0$ , e, portanto,  $\lim_{n \rightarrow \infty} \mathbf{P}^n = \mathbf{0}$  (matriz nula).

# Distribuição Limite não existente

Seja a cadeia de Markov dada abaixo:



$$\text{Então temos: } P^n = \begin{cases} P \text{ se } n \text{ é ímpar} \\ I \text{ se } n \text{ é par} \end{cases}$$

Logo, não existe a distribuição limite.

# Propriedades da Distribuição Limite

Seja o processo  $\{X_n: n = 0, 1, 2, \dots\}$  uma cadeia de Markov com matriz de probabilidade de transição  $P(p_{ij})$  tal que  $\pi_j^\infty = \lim_{n \rightarrow \infty} p_{ij}(n)$  existe para todo estado  $j$  e não depende do estado  $i$ . Então:

**PROPOSIÇÃO:** Se a cadeia é finita, então

- (a)  $\sum_j \pi_j^\infty = 1$  e
- (b)  $\pi_j^\infty = \sum_i \pi_i^\infty p_{ij}.$

# Propriedades da Distribuição Limite

**PROPOSIÇÃO:** Se a cadeia é infinita, então

- (a)  $\sum_j \pi_j^\infty \leq 1$  e
- (b)  $\pi_j^\infty = \sum_i \pi_i^\infty p_{ij}.$

# Convergência à Distribuição Estacionária

**PROPOSIÇÃO:** Seja o processo  $\{X_n: n = 0, 1, 2, \dots\}$  uma cadeia de Markov irredutível e recorrente. Defina

$$\tau_j = \min\{n \geq 1: X_n = j\}.$$

Então

$$P(\tau_j < \infty) = 1.$$

# Convergência à Distribuição Estacionária

**TEOREMA:** Seja o processo  $\{X_n : n = 0, 1, 2, \dots\}$  uma cadeia de Markov tal que

- (i) é irreductível,
- (ii) é aperiódica e
- (iii) possui uma única distribuição estacionária  $\pi = (\pi_j)_{j \in S}$ .

Então

$$\pi_j^\infty = \lim_{n \rightarrow \infty} p_{ij}(n) = \pi_j.$$

.

# Convergência de Cadeias de Markov

**TEOREMA:** Seja o processo  $\{X_n: n = 0, 1, 2, \dots\}$  uma cadeia de Markov tal que

- (i) é irredutível,
- (ii) é aperiódica e
- (iii) é recorrente positiva.

Então

(a) existe uma única distribuição estacionária  $\pi = (\pi_j)_{j \in S}$  dada por  $\pi_j = \frac{1}{\mu_j}$ ;

(b)  $\lim_{n \rightarrow \infty} p_{ij}(n) = \frac{1}{\mu_j}$ .

# O que é um Processo de Poisson?

Um processo de contagem  $\{N_t: t \geq 0\}$  é dito um Processo de Poisson de parâmetro  $\lambda > 0$ , se

- (i)  $N_0 = 0$
- (ii) O processo tem incrementos independentes e estacionários
- (iii) Para  $h$  pequeno

$$P(N_{t+h} - N_t = 1) = \lambda h + o(h)$$

$$P(N_{t+h} - N_t = 0) = 1 - \lambda h + o(h)$$

$$P(N_{t+h} - N_t \geq 2) = o(h)$$

# O que é um Processo de Poisson?

**TEOREMA:** Se  $\{N_t: t \geq 0\}$  é um Processo de Poisson, então para todo  $t \geq 0$ ,

$$P(N_t = k) = \frac{e^{-\lambda t}(\lambda t)^k}{k!}, \quad k = 0, 1, 2, \dots$$

**COROLÁRIO:** Para  $s, t \geq 0$ ,

$$\begin{aligned} P(N_{t+s} - N_t = k | N_u, u \leq t) &= P(N_{t+s} - N_t = k) \\ &= \frac{e^{-\lambda s}(\lambda s)^k}{k!}, \quad k = 0, 1, 2, \dots \end{aligned}$$

# O que é um Processo de Poisson?

**TEOREMA:** Se  $\{N_t : t \geq 0\}$  é um Processo de Poisson, então

- (a) para quase todo  $\omega$ , cada salto de  $N_t(\omega)$  tem medida 1 e
- (b) para  $s, t \geq 0$

$$E(N_{t+s} - N_t = k | N_u, u \leq t) = \lambda s.$$

# O que é um Processo de Poisson?

**TEOREMA:** Sejam  $T_1, T_2, T_3, \dots$  v.a.'s absolutamente contínuas com  $T_1$  representando o tempo da primeira chegada de um Processo de Poisson,  $T_j$  o tempo entre a  $(j - 1)$ -ésima chegada e a  $j$ -ésima chegada, para  $j \geq 2$ . Então  $T_j$  são v.a.'s i.i.d. com distribuição exponencial de parâmetro  $\lambda$ .

# Como simular um Processo de Poisson?

Uma vez que  $N_t = \max\{n \geq 1: T_1 + T_2 + \dots + T_n \leq t\}$  com  $T_j$ 's v.a.'s i.i.d. com distribuição exponencial de parâmetro  $\lambda$ , basta simular  $n$  realizações  $t_1, t_2, \dots, t_n$  da distribuição exponencial e os tempos de chegada do processo de Poisson são dados por

$$t_1, t_1 + t_2, t_1 + t_2 + t_3, \dots, t_1 + t_2 + t_3 + \dots + t_n$$

# O Processo de Poisson Não-Homogêneo

Um processo de contagem  $\{N_t: t \geq 0\}$  é dito um Processo de Poisson não-homogêneo de parâmetro  $\lambda(t) > 0$ , se

- (i)  $N_0 = 0$
- (ii) O processo tem incrementos independentes
- (iii) Para  $h$  pequeno

$$P(N_{t+h} - N_t = 1) = \lambda(t)h + o(h)$$

$$P(N_{t+h} - N_t = 0) = 1 - \lambda(t)h + o(h)$$

$$P(N_{t+h} - N_t \geq 2) = o(h)$$

# O Processo de Poisson Não-Homogêneo

**TEOREMA:** Se  $\{N_t: t \geq 0\}$  é um Processo de Poisson não-homogêneo, então para todo  $t \geq 0$ ,

$$P(N_{t+s} - N_t = k) = \frac{e^{-[m(s+t)-m(s)]}(m(s+t)-m(s))^k}{k!},$$

$$k = 0, 1, 2, \dots \text{ com } m(t) = \int_0^t \lambda(u)du.$$

# O Processo de Poisson Composto


O Processo de Poisson Composto é um processo a tempo contínuo  $\{X_t: t \geq 0\}$  da forma

$$X_t = \sum_{n=1}^{N_t} Y_n$$

com  $\{N_t: t \geq 0\}$  um processo de Poisson homogêneo de parâmetro  $\lambda > 0$  e  $\{Y_n: n = 1, 2, \dots\}$  são v.a.'s i.i.d. independentes do processo de Poisson.

# O Processo de Poisson Composto

As trajetórias do processo de Poisson Composto são do tipo



# O Processo de Poisson Composto

- $\sum_{n=1}^0 Y_n := 0$
- Quando  $Y_n = 1$ , para todo  $n$ , o processo de Poisson Composto recupera o Processo de Poisson homogêneo.
- A distribuição de  $X_t$  não é necessariamente de Poisson e depende da distribuição de  $Y$ , podendo, portanto, ter espaço de estados discretos ou contínuos.

# O Processo de Poisson Composto

- $E(X_t) = E(N_t)E(Y)$
- $X_t$  tem incrementos independentes e estacionários.
- Os tempos  $T_1, T_2, T_3, \dots$  entre as chegadas são os mesmos do Processo de Poisson  $\{N_t\}$  e, portanto, são v.a.'s i.i.d. com distribuição exponencial de parâmetro  $\lambda$ .
- $X_t$  satisfaz à propriedade de Markov.

# Processos de Nascimento e Morte

O processo a tempo contínuo  $\{X_t: t \geq 0\}$  é dito um processo de nascimento e morte com taxa de nascimento  $\lambda_k$  do estado  $k$  e taxa de morte  $\mu_k$  do estado  $k$  se as transições obedecem ao seguinte modelo


Para  $h$  pequeno (infinitesimal):

$$P(X_{t+h} = k+1 | X_t = k) = \lambda_k h + o(h)$$

$$P(X_{t+h} = k-1 | X_t = k) = \mu_k h + o(h)$$

$$P(X_{t+h} = k | X_t = k) = 1 - (\lambda_k + \mu_k)h + o(h)$$

# Processos de Nascimento e Morte



# Processos de Nascimento e Morte

Defina  $P(X_t = k) = p_k(t)$ . Então pode-se mostrar que a dinâmica em tempo contínuo de  $p_k(t)$  é dada pelas equações diferenciais recursivas:

$$p_0(t + h) = p_0(t)(1 - \lambda_0 h) + p_1(t)\mu_1 h + o(h)$$

$$\begin{aligned} p_k(t + h) \\ = p_k(t)(1 - (\lambda_k + \mu_k)h) + p_{k-1}(t)\lambda_{k-1}h + p_{k+1}(t)\mu_{k-1}h + o(h) \end{aligned}$$

O que nos dá

$$\frac{dp_0(t)}{dt} = -\lambda_0 p_0(t) + \mu_1 p_1(t)$$

$$\frac{dp_k(t)}{dt} = -(\lambda_k + \mu_k) p_k(t) + \lambda_{k-1} p_{k-1}(t) + \mu_{k-1} p_{k+1}(t)$$

# Processos de Nascimento e Morte

A distribuição estacionária  $p_k = \lim_{t \rightarrow \infty} p_k(t)$ , quando existe, é obtida das equações anteriores tomando  $\frac{dp_k(t)}{dt} = 0$  e acrescentando a condição normalizadora  $\sum_{k=0}^{\infty} p_k = 1$

O que nos dá


$$\begin{aligned}-\lambda_0 p_0 + \mu_1 p_1 &= 0 \\ -(\lambda_k + \mu_k) p_k + \lambda_{k-1} p_{k-1} + \mu_{k+1} p_{k+1} &= 0\end{aligned}$$

cuja solução é dada por

$$p_k = p_0 \left[ \prod_{i=0}^{k-1} \frac{\lambda_i}{\mu_{i+1}} \right] \quad \text{e} \quad p_0 = \frac{1}{1 + \sum_{k=1}^{\infty} \prod_{i=0}^{k-1} \frac{\lambda_i}{\mu_{i+1}}}$$

# O que é um Movimento Browniano?

O movimento Browniano é o nome dado ao movimento aleatório de partículas num líquido ou gás como consequência dos choques das moléculas do meio nas partículas.



- Robert Brown, em 1827, observou no microscópio pequenos grãos de pólen suspensos em água. Percebeu também que isso acontecia igualmente com partículas inorgânicas.
- Em 1900, Louis Bachelier observou que o mercado de ações tinha um aspecto visual muito semelhante ao movimento browniano a uma dimensão
- Em 1905, Albert Einstein, usando a teoria cinética dos gases, explicou quantitativamente os movimentos observados por Brown.

# Características do Movimento Browniano

- É de trajetórias contínuas.
- Os deslocamentos são erráticos e parecem não ter relação um com o outro em intervalos de tempo distintos.
- A partícula tem múltiplas colisões com as moléculas do meio.

# Modelo Matemático do Movimento Browniano

**Definição:** Um Movimento Browniano unidimensional de parâmetro  $\sigma^2$  é um processo estocástico  $\{B_t: t \geq 0\}$  com valores reais satisfazendo:

- $B_0 = 0$  quase certamente.
- Suas trajetórias são contínuas.
- Tem incrementos independentes.
- Para  $0 \leq s < t$ ,  $B_t - B_s \sim N(0, \sigma^2(t - s))$ .

$\{B_t: t \geq 0\}$  é também chamado de **Processo de Wiener**.

# Modelo Matemático do Movimento Browniano

**Definição:** Seja  $t \geq 0$  e sejam  $x$  e  $y$  reais. Definimos

$$p(t, y, x) = \frac{1}{\sqrt{2\pi\sigma^2 t}} e^{-(y-x)^2/2\sigma^2 t}$$

**PROPOSIÇÃO:** Seja  $\{B_t : t \geq 0\}$  um movimento Browniano. Então  $B_t \sim N(0, \sigma^2 t)$ , ou seja,  $B_t$  tem f.d.p. dada por  $p(t, 0, x)$ .

# Modelo Matemático do Movimento Browniano

**PROPOSIÇÃO:** Se  $0 < t_1 < t_2 < \dots < t_n$  então o vetor aleatório  $(B_{t_1}, B_{t_2}, \dots, B_{t_n})$  tem f.d.p. conjunta dada por

$$\begin{aligned}f(x_1, x_2, \dots, x_n) \\= p(t_1, 0, x_1)p(t_2 - t_1, x_1, x_2) \dots p(t_n - t_{n-1}, x_{n-1}, x_n).\end{aligned}$$

Assim

$$\begin{aligned}P(B_{t_1} \in A_1, B_{t_2} \in A_2, \dots, B_{t_n} \in A_n) = \\ \int_{A_1} \dots \int_{A_n} p(t_1, 0, x_1)p(t_2 - t_1, x_1, x_2) \dots p(t_n - t_{n-1}, x_{n-1}, x_n) dx_n \dots dx_1\end{aligned}$$

# Movimento Browniano – Outros Conceitos Básicos

Seja  $\{B_t: t \geq 0\}$  um movimento Browniano.

Definições:

- 1) Quando  $\sigma^2 = 1$  , o movimento Browniano é denominado padrão.
- 2) Denota-se por  $\{B_t^x: t \geq 0\}$  o movimento Browniano começando por  $x$ .
- 3) Um movimento Browniano n-dimensional é um processo da forma  $(B_1(t), \dots, B_n(t))$  cujas coordenadas são movimentos Brownianos unidimensionais independentes.

# Movimento Browniano – Outros Conceitos Básicos

**PROPOSIÇÃO:** Seja  $\{B_t : t \geq 0\}$  um movimento Browniano padrão. Então os seguintes resultados se verificam:

- (i)  $E(B_t) = 0.$
- (ii)  $Var(B_t) = E(B_t^2) = t.$
- (iii)  $Var(B_t - B_s) = |t - s|.$
- (iv)  $Cov(B_t, B_s) = \min(t, s).$

# O Movimento Browniano é um Processo Markoviano

**PROPOSIÇÃO:** O movimento Browniano  $\{B_t : t \geq 0\}$  é um processo de Markov, isto é,

para  $0 < t_1 < t_2 < \dots < t_n < t_{n+1}$

$$P(B_{t_{n+1}} \in A | B_{t_1} = x_1, B_{t_2} = x_2, \dots, B_{t_n} = x_n)$$

$$= P(B_{t_{n+1}} \in A | B_{t_n} = x_n)$$

# O Movimento Browniano é um Martingal Contínuo

**PROPOSIÇÃO:** O movimento Browniano  $\{B_t: t \geq 0\}$  é um martingal contínuo, isto é,  $E(B_t | B_u, 0 < u \leq s) = B_s$ .

***Teorema de Caracterização de Paul Lévy:*** Um processo  $\{X_t: t \geq 0\}$  é um movimento Browniano, se e somente se,

- $X_0 = 0$  quase certamente.
- Suas trajetórias são contínuas.
- $\{X_t: t \geq 0\}$  é um martingal.
- $\{X_t^2 - t: t \geq 0\}$  é um martingal.

# Como Simular um Movimento Browniano

Seja o passeio aleatório com  $X_0 = 0$

$$X_n = Y_1 + Y_2 + \cdots + Y_n$$


com  $Y_i$ 's variáveis aleatórias *i.i.d.* tais que

$$P(Y_i = +1) = P(Y_i = -1) = 1/2.$$

Assim  $E(Y_i) = 0$  e  $Var(Y_i) = 1$ , e com isso

$$E(X_n) = 0 \text{ e } Var(X_n) = n.$$

# Como Simular um Movimento Browniano



# Como Simular um Movimento Browniano

Tome agora uma nova escala de tempo como

$$\Delta t = \frac{1}{N}$$


para  $N$  um número natural, e para  $n = 1, 2, \dots$  defina

$$X_{n(\Delta t)} = \sqrt{\Delta t} Y_1 + \sqrt{\Delta t} Y_2 + \cdots + \sqrt{\Delta t} Y_n$$

Assim


$$E(X_{n(\Delta t)}) = 0 \text{ e } Var(X_{n(\Delta t)}) = n\Delta t.$$

# Como Simular um Movimento Browniano



# Movimento Browniano – Propriedades das Trajetórias

Seja  $\{B_t: t \geq 0\}$  um movimento Browniano padrão, como simulado na figura a seguir:



# Movimento Browniano – Propriedades das Trajetórias

Seja  $[a, b]$  um intervalo de tempo e seja

$$a = t_0 < t_1 < t_2 < \dots < t_n = b$$

uma partição finita de  $[a, b]$ .

Seja  $\Delta t = \max_i \{t_i - t_{i-1}\}$ .

**PROPOSIÇÃO:** A variação de  $\{B_t : t \geq 0\}$  sobre  $[a, b]$  é infinita quase certamente, isto é,

$$\lim_{\Delta t \rightarrow 0} \sup \sum_i |B_{t_{i+1}} - B_{t_i}| = \infty$$

quase certamente.

# Movimento Browniano – Propriedades das Trajetórias

**PROPOSIÇÃO:** A variação quadrática de  $\{B_t: t \geq 0\}$  sobre  $[a, b]$  é finita e vale o comprimento do intervalo, isto é,

$$\lim_{\Delta t \rightarrow 0} \sup \sum_i |B_{t_{i+1}} - B_{t_i}|^2 = b - a$$

em media quadrática.

**PROPOSIÇÃO:** O movimento Browniano  $\{B_t: t \geq 0\}$  não é diferenciável em nenhum ponto  $t \geq 0$ , quase certamente.

# Movimento Browniano – Propriedades das Trajetórias

Essas propriedades nortearam a criação do Cálculo Estocástico por Itô, estruturado em média quadrática, gerando resultados supreendentes como, por exemplo,

$$(dB_t)^2 = dt$$
$$\int_0^t B_s dB_s = \frac{1}{2} B_t^2 - \frac{1}{2} t$$



**OBRIGADO!**

**BOM ESTUDO DE PROCESSOS  
ESTOCÁSTICOS!**